复旦数学资料汇编
随机矩阵理论

来源：香蕉空间 Solution 资料库

2026 年 10 月 13 日

编者说明

本册按课程汇集原站讲义、笔记、习题及试卷，保持原资料内容。格式转换不构成数学证明审核。每篇保留来源网址；原站未建立的页面不编造正文。内容采用原站标注的 CC BY-SA 4.0 许可，署名与详细历史可由原网页查看。

目录

第一章 随机矩阵理论 **1**

1.1 笔记及习题解答: 随机矩阵理论 1
1.2 笔记及习题解答: 随机矩阵理论/Stieltjes 变换法 1
1.3 笔记及习题解答: 随机矩阵理论/半圆律矩方法的证明 4
1.4 策略与组合结构 4
1.5 半圆律 4
1.6 笔记及习题解答: 随机矩阵理论/导论 8
1.7 研究对象与现象 8
1.8 Ulam 问题 9
1.9 笔记及习题解答: 随机矩阵理论/弱收敛 9
1.10 连读函数空间 9
1.11 概率测度的收敛 10
1.12 $(\mathcal{R}, \mathcal{B})$ 中的随机概率测度 (random probability measure) 14
1.13 随机概率测度的各种收敛 17
1.14 笔记及习题解答: 随机矩阵理论/矩方法 19
1.15 矩问题 (Hamburger 问题) 19
1.16 概率测度的矩方法 20
1.17 随机概率测度的矩方法 21
1.18 半圆分布和 MP 分布的矩 22
1.19 RMT 中矩方法的应用 24
1.20 笔记及习题解答: 随机矩阵理论/行列式点过程 (Determinantal Point Process) 24
1.21 点过程 25
1.22 关联函数 25
1.23 行列式点过程 25
1.24 Gap probability (间隙概率) & Fredholm determinant 26
1.25 DPP & non-intersecting path 27
1.26 Tracy-Widom 分布 29
1.27 笔记及习题解答: 随机矩阵理论/随机矩阵的极限律 34
1.28 随机矩阵的定义及基本性质 34
1.29 特征值的经验分布 (empirical distribution) 35
1.29.1 Wigner 半圆律 35

1.29.2 Marchenko-Pastur 律 36
1.30 笔记及习题解答: 随机矩阵理论/高斯随机阵的解析分布 37
1.31 随机矩阵的定义方式 37
1.32 Gaussian Orthogonal Ensemble, GOE 37
1.33 高斯酉系综 (Gaussian Unitary Ensemble, GUE) 38
1.34 GUE 和 GOE 特征值分布的解析表达式 38
1.35 GUE 与 Hermite 核 40

第一章　随机矩阵理论

1.1　笔记及习题解答: 随机矩阵理论

原网页

comment| 这份讲义的内容和习题是 25 秋随机矩阵理论课程的，每届习题不同。

- 导论
- 高斯随机阵的解析分布
- 行列式点过程 (Determinantal Point Process)
- 弱收敛
- 随机矩阵的极限律
- 矩方法
- 半圆律矩方法的证明
- Stieltjes 变换法

1.2　笔记及习题解答: 随机矩阵理论/Stieltjes 变换法

原网页

习题 10. 设 $A \in \mathbb{C}^{n\times n}$ 可逆，$1 \le k \le n$，记 $A^{(k)}$ 为删去第 k 行和第 k 列得到的主子矩阵。记

$$r_k = (a_{k1}, \dots, a_{k,k-1}, a_{k,k+1}, \dots, a_{kn})$$

为 A 的第 k 行删去第 k 个分量得到的行向量，

$$c_k = (a_{1k}, \dots, a_{k-1,k}, a_{k+1,k}, \dots, a_{nk})^T$$

为 A 的第 k 列删去第 k 个分量得到的列向量。

我们已经在 $k = n$ 的情形证明了下列两个引理：

(i) 若 $A^{(n)}$ 可逆，则

$$A^{-1}(n,n) = \frac{1}{A(n,n) - r_n(A^{(n)})^{-1}c_n}.$$

(ii) 若 $A^{(n)}$ 可逆，则

$$\operatorname{tr} A^{-1} - \operatorname{tr}(A^{(n)})^{-1} = \frac{1 + r_n(A^{(n)})^{-2}c_n}{A(n,n) - r_n(A^{(n)})^{-1}c_n}.$$

请先证明

$$\left(V_k A V_k^T\right)^{(n)} = A^{(k)},$$

再利用结论

$$\left(V_k A V_k^T\right)^{(n)} = A^{(k)},$$

证明上述两个引理对任意 $k \in \{1, \ldots, n\}$ 也成立，即

(i') 若 $A^{(k)}$ 可逆，则

$$A^{-1}(k,k) = \frac{1}{A(k,k) - r_k (A^{(k)})^{-1} c_k}.$$

(ii') 若 $A^{(k)}$ 可逆，则

$$\operatorname{tr} A^{-1} - \operatorname{tr} (A^{(k)})^{-1} = \frac{1 + r_k (A^{(k)})^{-2} c_k}{A(k,k) - r_k (A^{(k)})^{-1} c_k}.$$

证明. 设 $A \in \mathbb{C}^{n \times n}$ 可逆，$1 \le k \le n$。记 $A^{(k)}$ 为 A 删去第 k 行和第 k 列得到的 $(n-1) \times (n-1)$ 主子矩阵。记

$$r_k = (a_{k1}, \ldots, a_{k,k-1}, a_{k,k+1}, \ldots, a_{kn}), \quad c_k = (a_{1k}, \ldots, a_{k-1,k}, a_{k+1,k}, \ldots, a_{nk})^T,$$

其中 a_{ij} 为 A 的 (i,j) 元素。

已知当 $k = n$ 时，若 $A^{(n)}$ 可逆，则成立

$$A^{-1}(n,n) = \frac{1}{A(n,n) - r_n (A^{(n)})^{-1} c_n}, \tag{1.1}$$

$$\operatorname{tr} A^{-1} - \operatorname{tr} (A^{(n)})^{-1} = \frac{1 + r_n (A^{(n)})^{-2} c_n}{A(n,n) - r_n (A^{(n)})^{-1} c_n}. \tag{1.2}$$

现需先证明等式

$$\left(V_k A V_k^T\right)^{(n)} = A^{(k)},$$

其中 V_k 为特定的置换矩阵，然后利用该结论证明对任意 $k \in \{1, \ldots, n\}$，若 $A^{(k)}$ 可逆，则

$$A^{-1}(k,k) = \frac{1}{A(k,k) - r_k (A^{(k)})^{-1} c_k}, \tag{1}$$

$$\operatorname{tr} A^{-1} - \operatorname{tr} (A^{(k)})^{-1} = \frac{1 + r_k (A^{(k)})^{-2} c_k}{A(k,k) - r_k (A^{(k)})^{-1} c_k}. \tag{2}$$

定义置换 σ 如下：

$$\sigma(i) = \begin{cases} i, & i < k, \\ n, & i = k, \\ i - 1, & k < i \le n. \end{cases}$$

其逆置换 σ^{-1} 为

$$\sigma^{-1}(j) = \begin{cases} j, & j < k, \\ k, & j = n, \\ j + 1, & k \le j \le n - 1. \end{cases}$$

令 V_k 为对应于 σ^{-1} 的置换矩阵，即 V_k 的第 i 行为单位矩阵的第 $\sigma^{-1}(i)$ 行。易见 V_k 是正交矩阵：$V_k^{-1}=V_k^T$，且 V_k^T 对应置换 σ（因为 V_k^T 的第 j 列为单位矩阵的第 $\sigma^{-1}(j)$ 列，故左乘 V_k^T 相当于按 σ 进行行置换）。

记 $B=V_kAV_k^T$。由定义，B 的元素为

$$B_{ij}=A_{\sigma^{-1}(i),\sigma^{-1}(j)},\qquad i,j=1,\dots,n.$$

考虑 B 的前 $n-1$ 行和前 $n-1$ 列构成的子矩阵 $B^{(n)}$，其元素为 B_{ij}，$i,j=1,\dots,n-1$。对于 $i,j=1,\dots,n-1$，有 $\sigma^{-1}(i),\sigma^{-1}(j)\in\{1,\dots,n\}\setminus\{k\}$，且映射

$$i\mapsto\sigma^{-1}(i),\quad i=1,\dots,n-1$$

正是 $\{1,\dots,n-1\}$ 到 $\{1,\dots,n\}\setminus\{k\}$ 的双射：

$$\sigma^{-1}(i)=\begin{cases}i, & i<k,\\ i+1, & i\geq k.\end{cases}$$

该双射恰好也是 $A^{(k)}$ 的行（列）指标与原矩阵 A 的行（列）指标之间的对应关系。具体地，若将 $A^{(k)}$ 的第 i 行对应原 A 的第 $\sigma^{-1}(i)$ 行，则 $A^{(k)}$ 的 (i,j) 元素为 $A_{\sigma^{-1}(i),\sigma^{-1}(j)}$。因此

$$B_{ij}=A_{\sigma^{-1}(i),\sigma^{-1}(j)}=A^{(k)}_{ij},\qquad i,j=1,\dots,n-1.$$

故 $B^{(n)}=A^{(k)}$，即

$$\left(V_kAV_k^T\right)^{(n)}=A^{(k)}.$$

设 $A^{(k)}$ 可逆。考虑矩阵 $B=V_kAV_k^T$。由已证等式知 $B^{(n)}=A^{(k)}$，故 $B^{(n)}$ 也可逆。此外，直接计算可得：

- B 的 (n,n) 元素：$B(n,n)=A_{\sigma^{-1}(n),\sigma^{-1}(n)}=A_{k,k}=A(k,k)$。
- B 的第 n 行除去第 n 个分量的行向量 r_n'：对 $j=1,\dots,n-1$，

$$B_{nj}=A_{\sigma^{-1}(n),\sigma^{-1}(j)}=A_{k,\sigma^{-1}(j)}=\begin{cases}a_{kj}, & j<k,\\ a_{k,j+1}, & j\geq k,\end{cases}$$

  因此 $r_n'=(a_{k1},\dots,a_{k,k-1},a_{k,k+1},\dots,a_{kn})=r_k$。
- B 的第 n 列除去第 n 个分量的列向量 c_n'：对 $i=1,\dots,n-1$，

$$B_{in}=A_{\sigma^{-1}(i),\sigma^{-1}(n)}=A_{\sigma^{-1}(i),k}=\begin{cases}a_{ik}, & i<k,\\ a_{i+1,k}, & i\geq k,\end{cases}$$

  因此 $c_n'=(a_{1k},\dots,a_{k-1,k},a_{k+1,k},\dots,a_{nk})^T=c_k$。

现在将已知的 $k=n$ 情形的两个引理应用于矩阵 B。由于 $B^{(n)}=A^{(k)}$ 可逆，由式子 (1) 得

$$B^{-1}(n,n)=\frac{1}{B(n,n)-r_n'(B^{(n)})^{-1}c_n'}.$$

代入 $B(n,n)=A(k,k)$，$r_n'=r_k$，$c_n'=c_k$，$B^{(n)}=A^{(k)}$，得

$$B^{-1}(n,n)=\frac{1}{A(k,k)-r_k(A^{(k)})^{-1}c_k}. \tag{3}$$

另一方面，由 $B = V_k A V_k^T$ 知 $B^{-1} = V_k A^{-1} V_k^T$。于是

$$B^{-1}(n,n) = (V_k A^{-1} V_k^T)_{n,n} = A^{-1}_{\sigma^{-1}(n),\sigma^{-1}(n)} = A^{-1}_{k,k} = A^{-1}(k,k).$$

代入式 (3) 即得式 (1)。

类似地，由式 (2) 应用于 B 得

$$\operatorname{tr} B^{-1} - \operatorname{tr}(B^{(n)})^{-1} = \frac{1 + r_n'(B^{(n)})^{-2} c_n'}{B(n,n) - r_n'(B^{(n)})^{-1} c_n'}.$$

注意 $\operatorname{tr} B^{-1} = \operatorname{tr}(V_k A^{-1} V_k^T) = \operatorname{tr} A^{-1}$，且 $\operatorname{tr}(B^{(n)})^{-1} = \operatorname{tr}(A^{(k)})^{-1}$。代入各量得

$$\operatorname{tr} A^{-1} - \operatorname{tr}(A^{(k)})^{-1} = \frac{1 + r_k (A^{(k)})^{-2} c_k}{A(k,k) - r_k (A^{(k)})^{-1} c_k},$$

此即式 (2)。

综上，我们证明了对于任意 $k = 1, \dots, n$，若 $A^{(k)}$ 可逆，则等式 (1) 和 (2) 成立。　□

1.3　笔记及习题解答: 随机矩阵理论/半圆律矩方法的证明

原网页

1.4　策略与组合结构

定义 1.4.1. 设 k 是正整数。

1. 一个着色（*coloring*）是一个序列 $\underline{c} = (c_1, \dots, c_k)$，其中 $c_i \in \{1, \dots, k\}$，且 $c_1 = 1$，$\forall a \in \{1, \dots, k-1\}$，$c_{a+1} \le 1 + \max\limits_{1 \le j \le a} \{c_j\}$。着色中的元素称为颜色。
2. 设 $\underline{t} \in [n]^k$ 是一个数组，$\underline{c}$ 是一个着色。称 $\underline{t}$ 匹配 $\underline{c}$，若

$$\forall i, j \in [k], \quad t_i = t_j \iff c_i = c_j.$$

有时也称 $\underline{c}$ 是 $\underline{t}$ 的着色，记作 $\underline{c} = \underline{c}(\underline{t})$。

一个着色可用于表明一个数组中哪些元素相同、哪些不同。一个数组仅能匹配一个着色。

例 1.4.1. $\underline{t} = (5, 1, 4, 13, 4)$，对应着色 $\underline{c} = (1, 2, 3, 4, 3)$。

一个着色对应 $n(n-1)\cdots(n-l+1)$ 个数组（其中 l 是颜色数）。

1.5　半圆律

$$\langle \sigma, x^k \rangle = \begin{cases} \frac{1}{\frac{k}{2}+1} \binom{k}{k/2}, & k \text{ even}, \\ 0, & k \text{ odd}. \end{cases}$$

对 Wigner 矩阵，ESD 的 k 阶矩：

$$\begin{aligned}\langle \sigma_n, x^k\rangle &= \frac{1}{n}\sum_{i=1}^{n}\lambda_i^k = \frac{1}{n}Tr(W_n^k) = \frac{1}{n}Tr\left(\left(\frac{1}{\sqrt{n}}X_n\right)^k\right)\\ &= \frac{1}{n^{1+k/2}}\sum_{i=1}^{n}(X_n^k)(i,i)\\ &= \frac{1}{n^{1+k/2}}\sum_{(t_1,\dots,t_k)\in[n]^k} X_n(t_1,t_2)\cdots X_n(t_k,t_1)\\ &= \frac{1}{n^{1+k/2}}\sum_{\underline{t}\in[n]^k} X_n(\underline{t}) \quad (\text{其中}X_n(\underline{t}) = X_n(t_1,t_2)\cdots X_n(t_k,t_1)).\end{aligned}$$

引理 1.5.1. 令 $n,k\in\mathbb{N}$，$n\geq k$。

1. $[k]^k$ 中最多有 $k!$ 种着色。

2. 设 $\underline{c}\in[k]^k$ 是具有 l 种颜色的着色，则匹配 $\underline{c}$ 的数组数为：

$$\#\{\underline{t}\in[n]^k : \underline{t}\sim\underline{c}\} = n(n-1)\cdots(n-l+1).$$

3. 对 $\underline{t}\in[n]^k$，记 $V(\underline{t}) = \{t_1,\dots,t_k\}$，则 $\underline{c}(\underline{t})$ 有 $\#V(\underline{t})$ 种颜色。故

$$\#\{\underline{t}'\in[n]^k : \underline{t}'\sim\underline{c}(\underline{t})\} = n(n-1)\cdots(n-\#V(\underline{t})+1).$$

每个数组 $\underline{t}\in[n]^k$ 可以张成一个 Euler 图：$\underline{t} = (t_1,\cdots,t_k)$.

$$\mathcal{G}(\underline{t}) = (V(\underline{t}), E(\underline{t}), \phi_{\underline{t}}),$$

其中 $V(\underline{t}) = \{t_1,\dots,t_k\}$（顶点集），

$E(\underline{t}) = \{e_1,e_2,\dots,e_k\}$（边集），

$\phi_{\underline{t}}(e_i) = (t_i,t_{i+1}),\quad t_{k+1}\equiv t_1.$

注 1.5.1. 图中顶点可以重复，可以含自环（*loop*）和多重边。

定义 1.5.1. $\forall\underline{t}\in[n]$, 定义 $\rho(\underline{t}) = \{(\rho_1(\underline{t}),\dots,\rho_k(\underline{t}))$, 其中 $\rho_i(\underline{t}) = \#\{\phi_{\underline{t}}(e)\mid e$ 是一个 l 重边$\}\}$. 称 $\rho(\underline{t})$ 为 $\underline{t}$ 的一个 *profile*.

这里，l 重边是指有 $l-1$ 个 $E(\underline{t})$ 中的元素 $e_2',\dots,e_l'$, 使得 $\phi_{\underline{t}}(e_i') = \phi_{\underline{t}}(e), i = 2,\dots,l.$ *(*有 l 条边连接两个顶点*)*

对任意 $l\in[k]$, 欧拉回路正好穿越 ρ_l 个不同的 l 重边, 故有 $k = \sum_{i=1}^{l} i\rho_i(\underline{t})$.

对任意 $k\in\mathbb{N}$，我们记 $\Pi(k) = \{\rho\in\{0,\dots,k\}^k \mid \rho$ 是某个$\underline{t}\in[n]^k$ 的 profile$\}$.

$$\begin{aligned}\langle \sigma_n, x^k\rangle &= \frac{1}{n^{1+\frac{k}{2}}}\sum_{\underline{t}\in[n]^k} X_n(\underline{t})\\ &= \sum_{\rho\in\Pi(k)}\frac{1}{n^{1+\frac{k}{2}}}\sum_{\underline{t}\in T^n(\rho)} X_n(\underline{t})\end{aligned}$$

其中 $T^n(\rho) = \{\underline{t}\in[n]^k \mid \rho(\underline{t}) = \rho\}$

引理 1.5.2. $\forall n,k\in\mathbb{N}, l\in\{1,\dots,k\}$. 有

$$\#\{\underline{t}\in[n]^k \mid \#V(\underline{t})\leq l\}\leq k^k\cdot n^l$$

证明. $[k]^k$ 满足最多有 l 个颜色的着色个数 $\leq k^k$.

与 $\underline{c}$ 对应的数组 $\underline{t}$ 的个数 $(n)_l = n(n-1)\cdots(n-l+1) \leq n^l$. □

为了使用之前随机概率测度收敛的定理，我们现在需要考察期望矩的收敛性，即

$$\mathbb{E}(\langle \sigma_n, x^k \rangle) = \sum_{\rho \in \Pi(k)} \frac{1}{n^{1+\frac{k}{2}}} \sum_{\underline{t} \in T^n(\rho)} \mathbb{E}(X_n(\underline{t}))$$

注 1.5.2. 对于这个期望矩，我们有以下两点观察：

(1)$\rho \in \Pi(k)$, $\rho_1 > 0$. $\forall \underline{t} \in T^n(\rho)$, 则 $\mathbb{E}X_n(\underline{t}) = 0$. *(*有非零单边，则 $X_n(t_1,t_2)\cdots X_n(t_k,t_1)$ 中，该边只出现一次，期望为 *0.)*

(2) $\forall \underline{t} \in [n]^k$, $|\mathbb{E}X_n(t)| \leq L_k$.

引理 1.5.3. 设 k 是任意自然数，则：

(1)$\#\Pi(k) \leq 4^k$.

(2)$n \in \mathbb{N}$, $\rho \in \Pi(k)$.

(a) $\forall \underline{t} \in T^n(\rho)$, $\#V(\underline{t}) \leq 1 + (\rho_1 + \cdots + \rho_l) - L(\underline{t})$，其中 $L(\underline{t})$ 是 $\mathcal{G}$ 中圈的个数。$\Rightarrow \#T^n(\rho) \leq k^k n^{1+\rho_1+\cdots+\rho_k}$.

(b)ρ 包含一个奇级重的边。$\forall \underline{t} \in T^n(P)$, $\#V(\underline{t}) \leq \rho_1 + \cdots + \rho_k$, $\Rightarrow \#T^n(\rho) \leq k^k n^{\rho_1+\cdots+\rho_k}$.

证明. (1) 若 ρ 是某个数组 $\underline{t} \in [n]^k$ 的 profile , 则 $\sum_{l=1}^{k} l\rho_l = k$, $\rho_l \in \{0, 1, \ldots, \lfloor \frac{k}{l} \rfloor\}$

故 $\Pi(k) \leq \prod_{l=1}^{k} (\frac{k}{l} + 1) = \prod_{l=1}^{k} \frac{k+l}{l} = \binom{2k}{k} \sim \frac{4^k}{\sqrt{\pi k}}$.

(2) (a) 记 $L(\underline{t}) = L_1(\underline{t}) + \cdots + L_k(\underline{t})$. $L_i(\underline{t})$ 是 $\underline{t}$ 中 i 重圈。$\rho_l - L_l(\underline{t})$ 可能贡献出新颜色 $\#V(t) \leq 1 + \sum_{i=1}^{l} (\rho_i - L_i(\underline{t})) = 1 + \sum_{i=1}^{l} \rho_i - L(\underline{t})$.

(b) 固定 $\underline{t}$ 中的一个 l 重边 (l 是奇数)，在循环中对应 $e_{i_1}, \ldots, e_{i_l}$. 由于 l 是奇数，存在 $k \in \{1, \ldots, l\}$，使得 e_{i_k} 和 $e_{i_{k+1}}$ 穿越的方向相同。

从 t_{i_k} 出发，$e_{i_1}, \ldots, e_{i_k}$ 都不会贡献新的顶点。顶点 $t_{i_{k+1}}$ 之前已经计入，故最多有 $\rho_{i_1} + \cdots + (\rho_{i_k} - 1) + \cdots + \rho_{i_{k+1}} = \rho_{i_1} + \cdots + \rho_{i_k}$ 个顶点。 □

现在要估计 $\frac{1}{n^{1+k/2}} \sum_{\underline{t} \in T^n(\rho)} X_n(\underline{t})$. 一共分以下三种情况讨论：

Case1:$\rho_1 = 0$ 且 $\rho_l > 0$，$l \geq 3$.

若 ρ 含奇数重边，$\#T^n(\rho) \leq k^k \cdot n^{\rho_1+\cdots+\rho_k}$

由于 $\sum_{i=1}^{k} i\rho_i = k \wedge (\rho_1 = 0)$，

$$\Rightarrow \sum_{i=1}^{k} \rho_i \leq \sum_{i \neq l} i\rho_i + 2\rho_l = k - (l-2)\rho_l \leq k - 1$$

故 $\sum_{i=1}^{k} \rho_i \leq \frac{k-1}{2}$.

若 ρ 不含奇数重边，$\#T^n(\rho) \leq k^k \cdot n^{1+\rho_1+\cdots+\rho_k}$ 且有 $1 + \sum_{i=1}^{k} \rho_i \leq \frac{k}{2}$，留做习题。

习题 9. 证明当 ρ 不含奇数重边时，有 $1 + \sum_{i=1}^{k} \rho_i \leq \frac{k}{2}$ 成立。

证明. 设 ρ 是一个不含奇数重边的 profile，即对所有奇数 l，有 $\rho_l = 0$。由 profile 的定义，我们有：

$$\sum_{l=1}^{k} l\rho_l = k$$

由于所有 l 均为偶数，可设 $l = 2m_l$，则：

$$\sum_{l=1}^{k}(2m_l)\rho_l = k \quad \Rightarrow \quad 2\sum_{l=1}^{k} m_l\rho_l = k$$

因此 k 必为偶数，记 $k = 2s$。

现在考虑 $\sum_{l=1}^{k} \rho_l$。由条件知存在某个 $l_0 \geq 3$（且 l_0 为偶数）使得 $\rho_{l_0} > 0$。由于所有 l 均为偶数且不为 0，故 $l \geq 2$，且对 l_0 有 $l_0 \geq 4$（因为 l_0 是偶数且 ≥ 3）。

于是：

$$k = \sum_{l=1}^{k} l\rho_l = l_0\rho_{l_0} + \sum_{l\neq l_0} l\rho_l \geq 4\rho_{l_0} + 2(\sum_{l=1}^{k}\rho_l - \rho_{l_0}) \geq 2\sum_{l=1}^{k}\rho_l + 2$$

即：

$$2s = k \geq 2\sum_{l=1}^{k}\rho_l + 2 \quad \Rightarrow \quad \sum_{l=1}^{k}\rho_l \leq s - 1$$

因此：

$$1 + \sum_{l=1}^{k}\rho_l \leq 1 + (s-1) = s = \frac{k}{2}$$

□

这样，对于这些 ρ,

$$\begin{aligned}
&\frac{1}{n^{1+\frac{k}{2}}} \sum_{\underline{t}\in T^n(\rho)} \mathbb{E}(X_n(\underline{t})) \\
&\leq \frac{L_k}{n^{1+\frac{k}{2}}} \#\{t \in T^n(\rho)\} \\
&\leq \frac{L_k}{n^{1+\frac{k}{2}}} \cdot k^k \cdot n^{\frac{k}{2}} = O\left(\frac{1}{n}\right) \to 0
\end{aligned}$$

Case2:$\rho_1 > 0, \mathbb{E}(X_n(t)) = 0.$

Case3:$\rho_2 = \frac{k}{2}$.(必须 k 是偶数才有这种情况). 这是唯一对 $\frac{1}{n^{1+\frac{k}{2}}} \sum_{\underline{t}\in T^n(\rho)} \mathbb{E}(X_n(\underline{t}))$ 的期望有渐近贡献的情况，即 ρ 只包含两重边。

设 $\rho^{(k)} := \{\rho^{(k)} \in \Pi(k), \rho^{(k)} = \frac{k}{2}$且$\rho_l^{(k)} = 0, (l \neq 2)\}$ 对这里的 $\underline{t}$，由于只有平方项，因此 $\mathbb{E}(X_n(\underline{t})) = 1$. 故

$$\frac{1}{n^{1+\frac{k}{2}}} \sum_{t\in\rho^{(k)}} \mathbb{E}(X_n(\underline{t})) = \frac{1}{n^{1+\frac{k}{2}}} \#\{\underline{t} \in \rho^{(k)}\}.$$

$\forall \underline{t} \in \rho^{(k)}$ 最多有 $\frac{k}{2} + 1$ 顶点。把 $T^n(\rho^{(k)})$ 做分解：

$$T^n_{\leq\frac{k}{2}}(\rho^{(k)}) = \{\underline{t} \in T^n(\rho^{(k)}), \#V(\underline{t}) \leq \frac{k}{2}\}$$

$$T^n_{\frac{k}{2}+1}(\rho^{(k)}) = \{\underline{t} \in T^n(\rho^{(k)}), \#V(\underline{t}) = \frac{k}{2}+1\}$$

由之前引理，$\#T^n_{\leq \frac{k}{2}}(\rho^{(k)}) \leq k^k \cdot n^{\frac{k}{2}}$, 从而

$$\begin{aligned}\frac{1}{n^{1+k/2}} \sum_{\underline{t}\in T^n(\rho^{(k)})} \mathbb{E}(X_n(\underline{t})) &= \frac{1}{n^{1+k/2}} \sum_{\underline{t}\in T^n_{\frac{k}{2}+1}(\rho^{(k)})} \mathbb{E}(X_n(\underline{t})) + \frac{1}{n^{1+k/2}} \sum_{\underline{t}\in T^n_{\leq \frac{k}{2}}(\rho^{(k)})} \mathbb{E}(X_n(\underline{t})) \\ &= \frac{1}{n^{1+k/2}} \sum_{\underline{t}\in T^n_{\frac{k}{2}+1}(\rho^{(k)})} \mathbb{E}(X_n(\underline{t})) + o(1) \\ &= \frac{1}{n^{1+k/2}} \#\{\underline{t} \in T^n_{\frac{k}{2}+1}(\rho^{(k)})\}\end{aligned}$$

为了计算 $T^n_{\frac{k}{2}+1}$ 中元素个数，计算所有着色的数量。由引理 2.1，满足这样着色的数组个数为 $n(n-1)\cdots(n-\frac{k}{2})$. 易见

$$\frac{n(n-1)\cdots(n-\frac{k}{2})}{n^{1+\frac{k}{2}}} \to 1 (n \to \infty).$$

1.6　笔记及习题解答: 随机矩阵理论/导论

原网页

定义 1.6.1. *Random Matrix* 是取矩阵值的随机变量。
一个矩阵 $A = (a_{ij})_{1\leq i,j\leq n}$，其中每个元素 a_{ij} 均为随机变量或随机选择。

例 1.6.1 (对称随机矩阵)**.** 考虑对称阵 $a_{ij} = a_{ji}$，且 $a_{ij} \in \{-1, 1\}$。

- 当 $n = 1$ 时: 有 *2* 种矩阵。
- 当 $n = 2$ 时: 有 *8* 种矩阵。

Stochastic Matrix 和 Random Matrix 不同，某种意义上可以理解为随机过程中的转移矩阵。

1.7　研究对象与现象

研究对象主要是随机矩阵的 (奇异) 特征值、特征向量。

- **半圆律 (Semicircle Law)**:
  对上述例子，将特征值数值绘制成直方图，在 N 很大时，会出现规律。当 $N \to \infty$，经过适当尺度化 (scaling) 后，特征值的密度函数趋向于 $\frac{1}{2\pi}\sqrt{4-x^2}$。
- **普适性现象 (Universality)**:
  特征值的宏观极限规律不依赖于矩阵元素的具体分布。例如，无论 a_{ij} 是来自：
  - $\{1, 2, 3, 4\}$
  - Gauss 分布
  - 其他独立同分布

  只要限制矩阵的对称性以保证实特征值，宏观现象是相似的。
- **循环律 (Circular Law)**:
  对于非对称的复矩阵 G，当 $N \to \infty$ 时，其特征值在复平面的单位圆内呈均匀分布。

1.8　Ulam 问题

定义 1.8.1. 令 $S_N := \{\pi | \pi : \{1,2,...,N\} \to \{1,2,...,N\}\}$ 为 N 阶置换群 *(permutation group)*。

对于一个置换 $\pi \in S_N$，如果存在下标序列 $1 \le i_1 < i_2 < \cdots < i_k \le N$ 使得 $\pi(i_1) < \pi(i_2) < \cdots < \pi(i_k)$，则称序列 $(\pi(i_1), \ldots, \pi(i_k))$ 为一个长度为 k 的**增长子列**。

$L_N(\pi)$ 定义为 π 中**最长增长子列**的长度。

例 1.8.1. 对于 $N = 5$，置换 $\pi : (1,2,3,4,5) \to (5,1,3,2,4)$。其增长子列有 *(1,3,4), (1,2,4)* 等。最长长度为 *3*，即 $L_5(\pi) = 3$。

在 S_N 上赋予均匀分布, 即 $P(\pi) = \frac{1}{N!}$。此时 $L_N(\pi) : S_N \to \mathbb{R}$ 成为一个随机变量。

我们关心的问题是：当 $N \to \infty$ 时，L_N 的分布是什么？

定义 $q_{n,N} := \text{Prob}(L_N(\pi) \le n) = \frac{f_{n,N}}{N!}$，其中 $f_{n,N} = \#\{\pi \in S_N | L_N(\pi) \le n\}$。

L_N 与下列问题有关

- S_N 的表示问题 (杨图，Young Tableaux)。
- 统计力学的粒子系统。
- 首达渗流问题、增长模型、排斥过程。
- 曲面上的随机拓扑。
- 排序问题: 对 N 本编号为 1 N 的书进行排序，需要操作的次数为 $n = N - L_N(\pi)$ 次才能恢复原始排序。

历史 (History)

- **1935**: Erdős-Szekeres, $E(L_N) \ge \frac{1}{2}\sqrt{N-1}$。
- **1961**: Ulam 用蒙特卡洛方法，猜测极限 $\lim_{N\to\infty} \frac{E(L_N)}{\sqrt{N}} = C$ 存在。
- **1968**: Hammersley, 猜测 $C = 2$。
- **1972**: Logan-Shepp, 证明了极限存在。
- **1977**: Vershik-Kerov, 证明了 $C \ge 2$, 从而确认了 $C = 2$。
- **1999**: Baik-Deift-Johansson, 证明了 L_N 的涨落分布：

$$\frac{L_N - 2\sqrt{N}}{N^{1/6}} \xrightarrow{\text{dist}} \chi$$

其中 χ 是 Tracy-Widom (TW) 分布，该分布也描述了 GUE 随机矩阵最大特征值的分布。

1.9　笔记及习题解答: 随机矩阵理论/弱收敛

原网页

1.10　连读函数空间

$\mathbb{R}$: 实轴, $\mathcal{B}$: Borel σ-代数, $f : \mathbb{R} \to \mathbb{R}$

$Supp(f) = \overline{\{x \in \mathbb{R} | f(x) \neq 0\}}$ 中闭集.

f 在无穷远处消失:$\lim_{x\to\pm\infty} f(x) = 0$.

几类常用连续函数空间:

- $C(\mathbb{R}) := \{f : \mathbb{R} \to \mathbb{R}$ 连续$\}$
- $C_b(\mathbb{R}) := \{f \in C(\mathbb{R}), f$ 有界$\}$
- $C_0(\mathbb{R}) := \{f \in C(\mathbb{R}), f$ 在无穷远处消失$\}$
- $C_c(\mathbb{R}) := \{f \in C(\mathbb{R}),$ 有紧支集$\}$

定理 1.10.1. *以上函数空间有如下性质:*

(1) $C_b(\mathbb{R})$ *是完备的但不可分*

(2) $C_0(\mathbb{R})$ *完备且可分*

(3) $C_c(\mathbb{R})$ *不完备但可分*

(4) $C_c(\mathbb{R})$ *在* $C_0(\mathbb{R})$ *中稠密.*

1.11　概率测度的收敛

$\mathcal{M}(\mathbb{R})$: $(\mathbb{R}, \mathcal{B})$ 上的测度全体

$\mathcal{M}_f(\mathbb{R})$: 有限测度全体

$\mathcal{M}_1(\mathbb{R})$: 概率测度全体

$\mathcal{M}_{\leq 1}(\mathbb{R})$: 次概率测度全体.

$$\mathcal{M}_1(\mathbb{R}) \subseteq \mathcal{M}_{\leq 1}(\mathbb{R}) \subseteq \mathcal{M}_f(\mathbb{R}) \subseteq \mathcal{M}(\mathbb{R})(\text{均是真包含}).$$

若 $\mu \in \mathcal{M}(\mathbb{R})$, f 可测, 记 $\langle \mu, f\rangle = \int f d\mu$. $\langle \mu, x^k\rangle = \int x^k d\mu$.

引理 1.11.1. $\mathcal{F} \subseteq C_b(\mathbb{R})$ *是一个线性空间且* $C_c(\mathbb{R}) \subseteq \mathcal{F}$, *则* $\forall \mu \in \mathcal{M}_f(\mathbb{R})$, *映射* $I_\mu : \mathcal{F} \to \mathbb{R}$,

$$f \to \langle \mu, f\rangle,$$

定义了 $\mathcal{F}$ *上的正有界连续泛函且算子范数* $||I_\mu||_{op} = \mu(\mathbb{R})$.

注 1.11.1. *正:* $f \geq 0$, $I_\mu(f) \geq 0$

$$||I_\mu||_{op} = \sup_{||f||=1} |I_\mu(f)| = \mu(\mathbb{R}).$$

证明. 先定义 Cutoff function:$\forall u > L \geq 0$, 定义 $\phi_L^u : \mathbb{R} \to [0, 1]$,

$$\phi_L^u(x) = \begin{cases} 1, & x \in [-l, l] \\ \frac{u-|x|}{u-L}, & l < |x| < u \\ 0, & |x| > u \end{cases}$$

只需证算子范数 $||I_\mu||_{op} = \mu(\mathbb{R})$.

$\forall k$, $\phi_k^{k+1} \in \mathcal{F}$.　$\phi_k^{k+1} \geq 0$,$||\phi_k^{k+1}|| = 1$.

$I_\mu(\phi_k^{k+1}) = \langle \mu, \phi_k^{k+1}\rangle \geq \mu([-k, k]) \Rightarrow ||I_\mu|| \geq \mu(\mathbb{R})$.

又 $\langle \mu, f\rangle = |\int f d\mu| \leq ||f||\mu(\mathbb{R})$,

$\Rightarrow ||I_\mu||_{op} \leq \mu(\mathbb{R}) \Rightarrow ||I_\mu||_{op} = \mu(\mathbb{R})$.　□

定理 1.11.1. ***(Riesz* 表示定理)** 设 $\mathcal{F}$ 满足 $C_c(\mathbb{R}) \subseteq \mathcal{F} \subseteq C_0(\mathbb{R})$ 的线性空间且装备无穷范数.

则对 $\mathcal{F}$ 上任何正有界连续泛函 I, $\exists! \mu \in \mathcal{M}_f(\mathbb{R})$, *s.t.* $I = I\mu$ *and* $||I||_{op} = \mu(\mathbb{R})$.

如何判定两个测度相同?

引理 1.11.2. 设 $\mu, \nu \in \mathcal{M}_f(\mathbb{R})$, 且 $\mathcal{F}$ 在 $C_c(\mathbb{R})$ 中的稠密子集.

(i) $\mu = \nu \iff \mu(I) = \nu(I)$, 其中 I 是边界测度为 *0* 的区间 $(\mu(\partial I) = \nu(\partial I) = 0)$

(ii)$\mu = \nu \iff \forall f \in C_c(\mathbb{R}), \langle \mu, f\rangle = \langle \nu, f\rangle \iff \forall f \in \mathcal{F}, \langle \mu, f\rangle = \langle \nu, f\rangle$ *(*由 *Riesz* 定理可得*)*

证明. (i): "⇒" ✓

"⇐" 只需说明在有限开集上测度相同. 注意到 $\forall \rho \in \mathcal{M}_f(\mathbb{R})$, $A_\rho := \{x \in \mathbb{R} | \rho(\{x\}) > 0\}$ 至多可数, 故 $\mathbb{R} \setminus (A_\mu \cup A_\nu)$ 在 $\mathbb{R}$ 中稠密.

$\forall a < b, \exists \{a_n\}, \{b_n\} \in \mathbb{R} \setminus (A_\mu \cup A_\nu)$ s.t. $a_n \uparrow a, b_n \downarrow b, a_n < b_n$.

故 $\mu((a,b)) = \lim_{n\to\infty} \mu((a_n, b_n)) = \lim_{n\to\infty} \nu((a_n, b_n)) = \nu((a,b))$. □

定义 1.11.1. 设 $\{\mu_n\}$ 是 $\mathcal{M}_{\leq 1}(\mathbb{R})$ 中的一个序列.

(1) $\{\mu_n\}_{n\in\mathbb{N}}$ 弱收敛 *(converge weakly)* 于 $\mu \in \mathcal{M}_1(\mathbb{R})$, 若 $\forall f \in C_b(\mathbb{R})$, 有 $\langle \mu_n, f\rangle \to \langle \mu, f\rangle$.

(2) $\{\mu_n\}_{n\in\mathbb{N}}$ 淡收敛 *(converge vaguely)* 到 $\mu \in \mathcal{M}_{\leq 1}(\mathbb{R})$, $\forall f \in C_c(\mathbb{R})$, $\langle \mu_n, f\rangle \to \langle \mu, f\rangle$.

注 1.11.2. *1) weak convergence ⇒ vague convergence*

2) $\forall f \in C_b(\mathbb{R})$, 都有 $\lim_{n\to\infty}\langle \mu_n, f\rangle = \langle \mu, f\rangle$. $\Rightarrow \mu \in \mathcal{M}_1(\mathbb{R})$*(*取 $f = 1$ 即可*).*

3) $\forall f \in C_c(\mathbb{R})$, $\mu_n \in \mathcal{M}_{\leq 1}(\mathbb{R})$, $\lim_{n\to\infty}\langle \mu_n, f\rangle = \langle \mu, f\rangle, \Rightarrow \mu \in \mathcal{M}_{\leq 1}(\mathbb{R})$

证明. $\phi_m^{m+1} \in C_c(\mathbb{R})$

$\langle \mu_n, \phi_m^{m+1}\rangle \to \langle \mu, \phi_m^{m+1}\rangle \quad \Rightarrow \langle \mu, \phi_m^{m+1}\rangle \leq 1.$

$\mu([-m,m]) \leq \langle \mu, \phi_m^{m+1}\rangle \leq 1 \Rightarrow \mu(\mathbb{R}) \leq 1.$

另一方面, $\mu \in \mathcal{M}_{\leq 1}(\mathbb{R})$, $\alpha = 1 - \mu(\mathbb{R}) \in [0,1]$.

令 $\mu_n = \mu + \alpha\delta_n$($\delta_n$ 是 n 处的 Dirac 函数), 则 $\mu_n(\mathbb{R}) = \mu(\mathbb{R}) + \alpha = 1$, 故 $\mu_n \in \mathcal{M}_1(\mathbb{R})$. 事实上, $\mu_n \to \mu$ vaguely，则 $\forall f \in C_c(\mathbb{R})$, $\langle \mu_n, f\rangle = \int f d\mu + \alpha f(n)$

由 $f \in C_c(\mathbb{R})$, $\langle \mu_n, f\rangle \to \langle \mu, f\rangle$.

□

4) $\mathcal{M}_1(\mathbb{R}) \subset \mathcal{M}_{\leq 1}(\mathbb{R})$ 概率测度在次概率测度中稠密 *(*在淡收敛意义下*).*

5) $\mu_n \in \mathcal{M}_1(\mathbb{R})$, $\mu \in \mathcal{M}_{\leq 1}(\mathbb{R})$ μ_n 弱/淡收敛至 $\mu \iff$ μ_n 的任何子列存在相应的收敛子列.

6) $\mu_n \to \mu$ *vaguely*

$\iff \forall f \in C_0(\mathbb{R})$, *s.t.* $\lim\limits_{n\to\infty}\langle \mu_n, f\rangle = \langle \mu, f\rangle$

这是因为 $C_c(\mathbb{R})$ 在 $C_0(\mathbb{R})$ 中稠密.

引理 1.11.3. 设 $\mu_n \to \mu$ *weakly,* $\mu_n, \mu \in \mathcal{M}_1(\mathbb{R})$. $h \in C(\mathbb{R})$. $\langle \mu_n, h\rangle \to \langle \mu, h\rangle$ 的一个充分条件为*:* $\exists$ 一个严格正的连续函数 $g : \mathbb{R} \to (0, +\infty)$，*s.t.* $\sup_n\langle \mu_n, g\rangle < \infty$ 且 $\frac{h}{g}$ 在无穷远处消失.

习题 6. 证明引理 *2.7.(*提示：用控制收敛定理*)*

证明. 由 Skorokhod 嵌入定理，$\mu_n \xrightarrow{w} \mu$，则存在一个概率空间 $(\Omega, \mathcal{F}, P)$ 和随机变量 $\{X_n\}, X$，使得 X_n 的分布为 μ_n，X 的分布为 μ，且 $X_n \xrightarrow{\text{a.e.}} X$。

由于 h 连续，故 $h(X_n) \xrightarrow{\text{a.e.}} h(X)$。

下证 $\{h(X_n)\}$ 一致可积。由于 $\frac{h}{g}$ 在无穷远处消失，故 $\exists C \geq 0$，使得 $|h| \leq Cg$。

故 $\sup_n \mathbb{E}[|h(X_n)|] \leq C \sup_n \langle \mu_n, g \rangle < +\infty$。

$\forall \epsilon > 0$，$\exists M > 0$，使得 $|x| > M$ 时，$|h(x)| < \frac{\epsilon g(x)}{2\mathbb{E}[g(X_n)]}$。

设 $|h(x)| \leq k_\epsilon$，$\forall x \in [-M, M]$。取 $k > k_\epsilon$，则对任何 n，$\{|h(X_n)| > k\} \subset \{|X_n| > M\}$。

因此：

$$\mathbb{E}[|h(X_n)| \cdot I_{\{|h(X_n)|>k\}}] \leq \mathbb{E}[|h(X_n)| \cdot I_{\{|X_n|>M\}}] \leq \frac{\epsilon}{2\mathbb{E}[g(X_n)]} \mathbb{E}[g(X_n)] = \frac{\epsilon}{2} < \epsilon$$

因此 $\{h(X_n)\}$ 一致可积。

由 Vitali 收敛定理，$\mathbb{E}[h(X_n)] \to \mathbb{E}[h(X)]$，即 $\langle \mu_n, h \rangle \to \langle \mu, h \rangle$。 □

淡收敛的极限未必是概率测度；淡收敛 + 紧性 (tightness) ⇒ 淡收敛的极限是概率测度。

定义 1.11.2. *$(\mathbb{R}, \mathcal{B})$ 上的一列概率测度 $\{\mu_n\}$ 被称为是紧的, 若 $\forall \epsilon > 0, \exists$ $\mathbb{R}$ 中的紧集 K, s.t. $\forall n$, $\mu_n(K^c) < \epsilon$. $K^c = \mathbb{R} \setminus K$.*

引理 1.11.4. *(判断紧性) 设 $\{\mu_n\}$ 是 $(\mathcal{R}, \mathcal{B})$ 中的一列概率测度, 若存在一个非负可测函数 $\phi : \mathbb{R} \to \mathbb{R}_+$. 满足 $\phi(x) \to \infty, x \to \pm\infty$ 及 $\sup_n \langle \mu_n, \phi \rangle < \infty$, 则 $\{\mu_n\}$ 是紧的.*

注 1.11.3. *$\phi(x) = x^2$ 时, 要验证紧性只需验证 $\sup_n \langle \mu_n, x^2 \rangle < \infty$，比较常用。*

证明. 记 $C := \sup_n \langle \mu_n, \phi \rangle$,

则

$$C \geq \langle \mu_n, \phi \rangle \geq \langle \mu_n, \chi_{[-k,k]^c} \inf_{|x|>k} \phi(x) \rangle$$

$$= \inf_{|x|>k} \phi(x) \cdot \mu_n([-k, k]^c)$$

由于 $\inf_{|x|>k} \phi(x) \to \infty, k \to \infty$, 故 $\mu_n([-k, k]^c)$ 是小量, 从而得到 $\{\mu_n\}$ 的紧性。 □

引理 1.11.5. *若 $\mu_n \to \mu$ vaguely, 其中 $\mu_n \in \mathcal{M}_1(\mathbb{R}), \mu \in \mathcal{M}_{\leq 1}(\mathbb{R})$.*

则下列结论等价:

(1) $\{\mu_n\}$ 是紧的.

(2) $\mu \in \mathcal{M}_1(\mathbb{R})$.

(3) $\mu_n \to \mu$ weakly.

证明. (1) ⇒ (3): 欲证 $\forall f \in C_b(R), \langle \mu_n, f \rangle \to \langle \mu, f \rangle$.

已知 $\langle \mu_n, f \rangle \to \langle \mu, f \rangle, f \in C_c(R)$.

记 $S := \max\{\|f\|_\infty, 1\}$

由于 $\{\mu_n\}$ 是紧的，有 $\forall s > 0, \exists k > 0, s.t. \quad \mu_n([-k, k]^c) \leq \frac{S}{2S}, \mu([-k, k]^c) \leq \frac{S}{2S}$.

记 ϕ_k^{k+1} 为之前定义的 cutoff function, 则结合上式即引理的淡收敛条件，得到：

$$\begin{aligned}|\langle\mu_n, f\rangle - \langle\mu, f\rangle| &\le |\langle\mu_n, f\rangle - \langle\mu_n, f\phi_k^{k+1}\rangle| \\ &\quad + |\langle\mu_n, f\phi_k^{k+1}\rangle - \langle\mu, f\phi_k^{k+1}\rangle| + |\langle\mu, f\rangle - \langle\mu, f\phi_k^{k+1}\rangle| \\ &\le \langle\mu_n, |f||1-\phi_k^{k+1}|\rangle + \epsilon(\text{由淡收敛}) + \langle\mu, |f||\phi_k^{k+1}-1|\rangle \\ &\le S\cdot\frac{\epsilon}{2S} + \epsilon + S\cdot\frac{\epsilon}{2S} = 2\epsilon.\end{aligned}$$

(2) ⇒ (1): 欲证 $\mu \in \mathcal{M}_1(\mathbb{R}) \Rightarrow \{\mu_n\}$ 是紧的。‘

$$\begin{aligned}\mu_n([-k-1, k+1]) &\ge \langle\mu_n, \phi_k^{k+1}\rangle \\ &\ge \langle\mu_n, \phi_k^{k+1}\rangle - |\langle\mu, \phi_k^{k+1}\rangle - \langle\mu_n, \phi_k^{k+1}\rangle|\end{aligned}$$

由于 $\mu \in \mathcal{M}_1(\mathbb{R})$, 选择$k$足够大, $s.t.\langle\mu, \phi_k^{k+1}\rangle \ge 1-\frac{\epsilon}{2}$. 又由于 $\mu_n \to \mu$ vaguely，故 $\exists N, s.t.\forall n > N,\quad |\langle\mu_n, \phi_k^{k+1}\rangle - \langle\mu, \phi_k^{k+1}\rangle| \le \frac{\epsilon}{2}$.

这推出 $n > N$ 时，$\mu_n([-k-1, k+1]) \ge 1-\epsilon$.

$\forall i \in \{1, \dots, N\}, \exists k_i, s.t.\mu_i([-k_i, k_i]) \ge 1-\epsilon$.

从而取 $k^* = \max\{k_1, \dots, k_N, k+1\}$, 则 $\forall n \in \mathbb{N}^*, \mu_n[-k^*, k^*] > 1-\epsilon$. 从而 $\{\mu_n\}$ 是紧的。

(3) ⇒ (2): 之前证过。 □

引理 1.11.6. $\{\mu_n\}$ 是从 $\mathcal{M}_1(\mathbb{R})$ 中的序列，则

(1) $\{\mu_n\}$ 有一个子列淡收敛至某个 $\mu \in \mathcal{M}_{\le 1}(\mathbb{R})$.

(2) $\{\mu_n\}$ 是紧的，则 $\{\mu_n\}$ 有一个子列弱收敛至某个 $\mu \in \mathcal{M}_1(\mathbb{R})$.

证明. Helly 选择定理 + Riesz 表示. □

定理 1.11.2. 设 $\{g_k\}_{k\in\mathbb{N}}$ 是 $C_C(R)$ 中的一个稠密序列，则:

(1) 若 $\mu, \mu_n \in \mathcal{M}_1(\mathbb{R})$. 则

$$\mu_n \to \mu \quad weakly \Leftrightarrow \forall k \in \mathbb{N}, \langle\mu_n, g_k\rangle \to \langle\mu, g_k\rangle.$$

(2)$\forall \mu, \nu \in \mathcal{M}_1(\mathbb{R})$, 定义

$$d_M(\mu, \nu) = \sum_{k\in\mathbb{N}} \frac{|\langle\mu, g_k\rangle - \langle\nu, g_k\rangle|}{(1+|\langle\mu, g_k\rangle - \langle\nu, g_k\rangle|)\cdot 2^k}$$

则 d_M 是 $\mathcal{M}_1(\mathbb{R})$ 中的度量且有：$\{\mu_n\} \in \mathcal{M}_1(\mathbb{R})$ 弱收敛到

$\mu \iff d_M(\mu_n, \nu) \to 0, n \to +\infty.$

(3)$(\mathcal{M}_1(\mathbb{R}), d_M)$ 是可分但不完备的度量空间。

证明. (1) 只需证充分性。事实上，条件结合稠密性可以得到 μ_n 淡收敛到 μ, 又结合 $\mu \in \mathcal{M}_1(\mathbb{R})$ 即得到弱收敛。

(2) 在 $\mathbb{R}^{\mathbb{N}}$ 中引入度量 ρ, 使得对任何 $x, y \in \mathbb{R}^{\mathbb{N}}$,

$$\rho(x, y) = \sum_{k\in\mathbb{N}} \frac{|x(k)-y(k)|}{2^k(1+|x(k)-y(k)|)}.$$

在此度量下，$(Z_n) \in \mathbb{R}^{\mathbb{N}} \to Z \in \mathbb{R}^{\mathbb{N}}$，　$n \to +\infty$ 等价于每个分量 $Z_n(i) \to Z(i)$, 也等价于 $\rho(Z_n, Z) \to 0, n \to \infty$. 从而由于有理数在实数中稠密，$(\mathbb{R}^{\mathbb{N}}, \rho)$ 是一个可分度量空间。

定义如下映射：

$$T : \mathcal{M}_1(\mathbb{R}) \to \mathbb{R}^N$$
$$\mu \quad \to (\langle \mu, g_1 \rangle, \langle \mu, g_2 \rangle, \ldots)$$

则 T 是单射：

$$T(\mu) = T(\nu) \quad \Longleftrightarrow \langle \mu, g_k \rangle = \langle \nu, g_k \rangle \Longleftrightarrow \mu = \nu$$

又因为 $d_M(\mu, \nu) = \rho(T(\mu), T(\nu))$, 故可见 $(\mathcal{M}_1(\mathbb{R}), d_M)$ 是一个度量空间。T 不仅是单射，而且保度量、连续。因此 T 的像集作为 $(\mathbb{R}^{\mathbb{N}}, \rho)$ 的子集也是一个可分空间。$(\mathcal{M}_1(\mathbb{R}), d_M)$ 同胚于 T 的像集，故也是可分的。

(3) 可分性已在 (2) 重证明，不完备性则可如下给出。若 $\mu_n \to \mu$ vaguely，也有 $d_M(\mu_n, \mu) \to 0$，而此时 μ 未必是概率测度。　□

1.12　$(\mathcal{R}, \mathcal{B})$ 中的随机概率测度 (random probability measure)

有了度量 $((\mathcal{M}_1(\mathbb{R}), d_M)$，拓扑可通过收敛序列来重构。在 $\mathcal{M}_1(\mathbb{R})$ 中装备弱收敛拓扑及相应的 $Borel - \sigma$ 代数。

$\forall f \in C_b(R)$,

$$I_f : \mathcal{M}_1(\mathbb{R}) \to \mathbb{R}$$
$$\mu \to I_f(\mu) = \langle \mu, f \rangle.$$

则 I_f 是 $\mathcal{M}_1(\mathbb{R})$ 上的连续函数。

随机概率测度（取值于 $M_1(R)$ 的随机变量）

定义 1.12.1. 令 $(\Omega, \mathcal{A}, \mathbb{P})$ 是一个概率空间。

(i) $(\mathbb{R}, \mathcal{B})$ 上的随机概率测度是一个可测映射:

$$\mu : \Omega \to M_1(R), \quad \omega \to \mu(\omega, .) \in \mathcal{M}_1(\mathbb{R})$$

(ii) 从 $(\Omega, \mathcal{A})$ 到 $(\mathbb{R}, \mathcal{B})$ 的随机核，是指映射

$$\mu : \Omega \times \mathcal{B} \to \mathbb{R} \quad \text{满足}$$

(a) $\forall \omega \in \Omega, \quad \mu(\omega, .)$ 是 $(\mathbb{R}, \mathcal{B})$ 上的概率测度；

(b) $\forall B \in \mathcal{B}, \quad \mu(., B)$ 是 $\mathcal{A} - \mathcal{B}$ 可测的。

引理 1.12.1. 设 $(\Omega, \mathcal{A}, P)$ 是一个概率空间。

(a) 映射 $M : \Omega \times \mathcal{B} \to \mathbb{R}$ 是一个随机概率测度 $\Longleftrightarrow$ 它是一个随机核；

(b) 若 μ 是 $(\Omega, \mathcal{A})$ 到 $(\mathbb{R}, \mathcal{B})$ 的随机核且 $f : \mathbb{R} \to \mathbb{R}$ 是有界可测函数，则 $w \to \langle \mu(\omega), f \rangle$ 个是可测的且有上界 $\|f\|_\infty$.

证明. 先证明 (b): 对任何 $\omega \in \Omega$,

$$|\langle \mu(\omega), f\rangle \le \langle \mu(\omega), |f|\rangle \le \langle \mu(\omega), \|f\|_\infty\rangle \le \|f\|_\infty$$

从而映射有上界 $\|f\|_\infty$. 下证可测性：由随机核定义，$\forall B \in \mathcal{B}, \omega \to \mu(\omega, B)$ 可测。从而对非负简单函数

$$f = \sum_{i=1}^{n} \alpha_i \chi_{B_i}, n \in \mathbb{N}, \alpha_i \ge 0, B_i \in \mathcal{B}$$

有 $\omega \to \langle \mu(\omega), f\rangle$ 可测。若 f 是非负有界可测函数，可以用单增简单函数列 $\{f_n\}$ 点态逼近, 则由单调收敛定理，

$$\langle \mu(\omega), f_n\rangle \to \langle \mu(\omega), f\rangle.$$

这推出对非负有界可测函数 f，$\omega \to \langle \mu(\omega), f\rangle$ 可测。若 f 有界可测，可以分成正负部分 f_+, f_-，类似实分析的操作也可得结论。

(a) 先证充分性：即随机核 $\Rightarrow$ 随机概率测度。

$$\mu : \Omega \to \mathcal{M}_1(\mathbb{R}), \quad \omega \to \mu(\omega) \in \mathcal{M}_1(\mathbb{R})$$

需说明 $w \to \mu(w, \cdot)$ 可测. 只需证明 $(\mathcal{M}_1(\mathbb{R}), d_m)$ 中的开球原像原像是可测的. $\nu \in \mathcal{M}_1(\mathbb{R}), \quad \epsilon > 0$ 任意小, 对应的开球为

$$B_\epsilon^{\mathcal{M}_1(\mathbb{R})} = \{\nu' \in M_1(R), \quad d_M(\nu', \nu) < \epsilon\}$$

$$\mu^{-1}(B_\epsilon^{\mathcal{M}_1(\mathbb{R})}(\nu)) = \{\omega \in \Omega, \quad d_M(\mu(\omega), \nu) < \epsilon\} = d_M(\mu(\cdot), \nu)^{-1}(0, \epsilon).$$

由于

$$d_M(\mu(\omega), \nu) = \sum_{k=1}^{\infty} \frac{\langle \mu(w), g_k\rangle - \langle \nu, g_k\rangle}{2^k(1 + |\langle \mu(w), g_k\rangle - \langle \nu, g_k\rangle|)}$$

又$\omega \to \langle \mu(\omega), f\rangle, \quad \forall f \in C_b(R)$可测 (由 (b) 的结论).

$$\therefore \omega \to d_M(\mu(\omega), \nu)\text{可测}$$

再证必要性：即随机概率测度 $\Rightarrow$ 随机核。要说明以下两点：

(a) $\mu(w, \cdot) \in M_1(R)$.(已经是条件)

(b) 要证明 $\forall B \in \mathcal{B}, \quad \omega \to \mu(\omega, B)$ 可测

当 B 为 $\mathbb{R}$ 中有界开区间 (a, b) 时，记 $\epsilon = \frac{b-a}{4}$. 构造以下函数：

$$\phi_n(x) = \begin{cases} 1, & (a + \frac{\epsilon}{n}, b - \frac{\epsilon}{n}) \\ 0, & \mathbb{R}\backslash(a, b) \\ \text{线性函数}, & (a, a + \frac{\epsilon}{n}) \cup (b - \frac{\epsilon}{n}, b) \end{cases}$$

则 ϕ_n 连续有界，且单调上升趋于 $\chi_{(a,b)}(x)$.

结合 $I_{\phi_n}(\mu) = \langle \mu, \phi_n \rangle$ 连续及 (a), 由于可测映射复合连续映射仍然可测，故 $\forall n \in \mathbb{N}, \quad \omega \to \langle \mu(\omega), \phi_n \rangle$ 可测。

由单调收敛定理，

$$\lim_{n\to\infty} \langle \mu(\omega), \phi_n \rangle = \langle \mu(w), \chi_{\{a,b\}} \rangle = \mu(\omega, (a,b))$$

从而 $\mu(\cdot, (a,b))$ 是 $\mathcal{A} - \mathcal{B}$ 可测的。

令 $\mathcal{G} := \{B \in \mathcal{B} : \omega \to \mu(\cdot, B)$可测$\}$，可以验证 $\mathcal{G}$ 是 Dynkin 系统，从而 $\mathcal{G} = \mathcal{B}$.

□

例 1.12.1. 设 $Y_1, \ldots, Y_n$ 是 $(\Omega, \mathcal{A}, \mathbb{P})$ 上的实值随机变量。

$$\rho := \frac{1}{n} \sum_{i=1}^{n} \delta_{Y_i}$$

是 $(\mathbb{R}, \mathcal{B})$ 上的随机概率测度，称为 (Y_i) 的经验分布（*empirical distribution*）.

$$\forall w \in \Omega, \quad \rho(w) = \frac{1}{n} \sum_{i=1}^{n} \delta_{Y_i(w)} \in \mathcal{M}_1(\mathbb{R})$$

$$\forall B \in \mathcal{B}, \quad w \to \rho(w, B) = \frac{1}{n} \sum \delta_{Y_i(w)}(B) = \frac{1}{n} \sum \chi_B(Y_i(w)) \quad \text{可测}$$

$\rho(B)$ 表示 Y_i 落在 B 中的比例。定义 $F_\rho(x) := \rho((-\infty, x]), \quad \forall x \in \mathbb{R}$, 称为随机分布函数。

设 μ 是一个随机概率测度，$B \in \mathcal{B}$，则 $\mu(B)$ 是一个有界随机变量。$\mathbb{E}\mu(B)$ 是 μ 限制在 B 中的期望质量，是一个确定的概率测度。

定理 1.12.1. 设 $(\Omega, \mathcal{A}, \mathbb{P})$ 是概率空间，μ 是 $(\mathbb{R}, \mathcal{B})$ 上的一个随机概率测度。

(a)

$$\overline{\mu} : \mathcal{B} \to [0,1]$$
$$B \to \overline{\mu}(B) = \int_\Omega \mu(\omega, B) \mathbb{P}(dw) = \mathbb{E}\mu(B)$$

是从 $\mathcal{M}_1(\mathbb{R})$ 中的一个元素，被称为期望测度。

(b) $\forall$ 非负可测函数 $f : \mathbb{R} \to \mathbb{R}_+$ 是可积的 $\iff \langle \mu, f \rangle$ 是 $\mathbb{P}-$ 可积的，且有

$$\langle \overline{\mu}, f \rangle = \int_{\mathbb{R}} f(x) \overline{\mu}(dx) = \int_\Omega \int_{\mathbb{R}} f(x) \mu(\omega, dx) P(dx) = \mathbb{E}\langle \mu, f \rangle.$$

上式对任何有界可测函数 $f : \mathbb{R} \to \mathbb{R}$ 也成立。

(c) $f : \mathbb{R} \to \mathbb{R}$ 是 $\overline{\mu}$-可积的，则 $\langle \mu, f \rangle$ 是 $P-$ 可积的且有

$$\langle \overline{\mu}, f \rangle = \mathbb{E}\langle \mu, f \rangle.$$

注： 用 $\mathbb{E}\mu$ 代替 $\overline{\mu}$，若 $\mathbb{E}\langle \mu, \|f\| \rangle < \infty$，则 f 是 $\mathbb{E}\mu$-可积的，且

$$\langle \overline{\mu}, f \rangle = \langle \mathbb{E}\mu, f \rangle = \mathbb{E}\langle \mu, f \rangle.$$

证明. (a) 留作练习。

(b) 设 $f(x)=\sum_{i=1}^{n}\alpha_i\chi_{B_i},\quad n\in\mathbb{N},\alpha_i\geq 0,B_i\in\mathcal{B}$. 则

$$\langle\overline{\mu},f\rangle=\sum_{i=1}^{n}\alpha_i\overline{\mu}(B_i)=\sum_{i=1}^{n}\alpha_i\mathbb{E}\mu(B_i)=\mathbb{E}\langle\mu,f\rangle$$

若 f 非负可测，则存在简单函数列 f_n，$f_n\uparrow f$，由单调收敛定理，

$$\langle\overline{\mu},f\rangle=\lim_{n\to\infty}\langle\overline{\mu},f_n\rangle=\lim_{n\to\infty}\mathbb{E}\langle\mu,f_n\rangle=\mathbb{E}\langle\mu,f\rangle$$

从而，若 f 是 μ-可积的 $\Longleftrightarrow\langle\mu,f\rangle$ 是 $\mathbb{P}$-可积的，且 $\langle\overline{\mu},f\rangle=\mathbb{E}\langle\mu,f\rangle$.

若 $f:\mathbb{R}\to\mathbb{R}$ 可测且有界，则存在 $c\in\mathbb{R}$，使得 $f(x)+C$ 非负。

$$\langle\overline{\mu},f\rangle=\langle\overline{\mu},f+C\rangle-C=\mathbb{E}\langle\mu,f+C\rangle-C=\mathbb{E}\langle\mu,f\rangle.$$

(c) 若 $f:\mathbb{R}\to\mathbb{R}$ 是 $\overline{\mu}$-可积的，则 $f=f_+-f_-$，$f_\pm$ 非负可测且 $\mathbb{P}$-可积。

由 (b) 知，$\langle\mu,f_\pm\rangle$ 是 $\mathbb{P}$-可积。故 $\langle\mu,f_+\rangle-\langle\mu,f_-\rangle=\langle\mu,f\rangle$ $\mathbb{P}$-可积。

$$\langle\overline{\mu},f\rangle=\langle\overline{\mu},f_+\rangle-\langle\overline{\mu},f_-\rangle=\mathbb{E}\langle\mu,f_+\rangle-\mathbb{E}\langle\mu,f_-\rangle=\mathbb{E}\langle\mu,f\rangle.$$

□

习题 7. 证明定理 *3.4(a).*

证明. 由随机概率测度定义，$\mu(\omega,\cdot)\in\mathcal{M}_1(\mathbb{R})$，$\forall\omega\in\Omega$。

从而积分 $\int_\Omega\mu(\omega,B)\mathbb{P}(d\omega)$ 自动满足非负性和可列可加性，只需验证规范性。

而由于 $\mu(\omega,\cdot)\in\mathcal{M}_1(\mathbb{R})$：

$$\int_\Omega\mu(\omega,\mathbb{R})\mathbb{P}(d\omega)=\int_\Omega 1\mathbb{P}(d\omega)=1$$

期望测度 $\overline{\mu}(B)=\mathbb{E}[\mu(B)]$ 是概率测度。 □

1.13　随机概率测度的各种收敛

定义 1.13.1. *(依期望弱收敛，converges weakly in expectation)* 设 $\{\mu_n\}$ 和 μ 是 $(\mathbb{R},\mathcal{B})$ 上的随机概率测度，称 $\{\mu_n\}$ 是依期望弱收敛到 μ，若期望概率序列 $\{\mathbb{E}\mu_n\}$ 弱收敛到 $\mathbb{E}\mu$。即 $\forall f\in C_b(\mathbb{R})$，

$$\langle\mathbb{E}\mu_n,f\rangle\xrightarrow{n\to\infty}\langle\mathbb{E}\mu,f\rangle\quad\text{亦即}\quad\mathbb{E}\langle\mu_n,f\rangle\xrightarrow{n\to\infty}\mathbb{E}\langle\mu,f\rangle$$

定义 1.13.2. 设 $\{Y_n\}_{n\in\mathbb{N}}$ 和 Y 是定义在概率空间 $(\Omega,\mathcal{A},\mathbb{P})$ 且取值于某度量空间 (X,d) 的随机变量。

(i) 称 Y_n 依概率收敛到 Y，若 $d(Y_n,Y)$ 依概率收敛到 0，即

$$P\{\omega;d(Y_n,Y)\geq\epsilon\}\to 0$$

(ii) 称 Y_n 几乎处处收敛到 Y，若 $d(Y_n,Y)$ 几乎处处收敛到 0。

注 1.13.1. 几乎处处收敛 $\Rightarrow$ 依概率收敛。

定义 1.13.3. 设 $(\Omega, \mathcal{A}, \mathbb{P})$ 是概率空间，μ 和 $\{\mu_n\}_{n\in\mathbb{N}}$ 是 $(\mathbb{R}, \mathcal{B})$ 上的随机概率测度。下面 d 是之前引进的两个概率测度之间的度量。

(i) 称 $\{\mu_n\}$ 依概率弱收敛到 μ，若 $d(\mu_n, \mu) \to 0$ *in prob.*

(ii) 称 $\{\mu_n\}$ 几乎处处弱收敛到 μ，若 $d(\mu_n, \mu) \to 0$ *a.e.*

定理 1.13.1. 几种收敛的等价定义

(i) 依概率弱收敛

(a) $\{\mu_n\}$ 依概率弱收敛到 μ，$d(\mu_n, \mu) \to 0$ *in prob.*

(b) 若 d 是 $\mathcal{M}_1(\mathbb{R})$ 中的一个刻画弱收敛的度量，$d(\mu_n, \mu) \to 0$ *in prob.*

(c) $\forall f \in C_b(\mathbb{R})$，有界实值随机变量序列 $\langle \mu_n, f\rangle$ 依概率收敛到 $\langle \mu, f\rangle$，即

$$P(|\langle \mu_n, f\rangle - \langle \mu, f\rangle| > \epsilon) \xrightarrow{n\to+\infty} 0.$$

(ii) 几乎处处弱收敛

(a) $\{\mu_n\}$ 几乎处处弱收敛到 μ，$d(\mu_n, \mu)$ 几乎处处收敛到 0.

(b) 对几乎所有 $\omega \in \Omega$（关于 $\mathbb{P}$），$\mu_n(\omega)$ 弱收敛到 $\mu(\omega)$.

(c) 若 d 是 $\mathcal{M}_1(\mathbb{R})$ 中刻画弱收敛的度量,$d(\mu_n, \mu) \to 0$,　*a.e.*

(d) $\forall f \in C_b(\mathbb{R}), \langle \mu_n, f\rangle \to \langle \mu, f\rangle$,　*a.e.*

即 $\forall f \in C_b(\mathbb{R}), [\langle \mu_n, f\rangle \to \langle \mu, f\rangle]$，方框表示这个集合测度为 *1*.

(e) 几乎处处对所有 $f \in C_b(\mathbb{R}), \langle \mu_n, f\rangle$ 收敛到 $\langle \mu, f\rangle$，即 $[\forall f \in C_b(\mathbb{R}), \langle \mu_n, f\rangle \to \langle \mu, f\rangle]$.

定理 1.13.2. *(*三种收敛之间的关系*)* $\{\mu_n\}, \mu$ 为随机概率测度。

(i) $\mu_n \to \mu$　*weakly a.s.* $\Rightarrow \mu_n \to \mu$　*weakly in prob.*

(ii) $\mu_n \to \mu$　*weakly in prob.* $\Rightarrow \mu_n \to \mu$　*weakly in expectation*

证明. (i) 显然。

(ii) 先证明一个引理。

引理 1.13.1. 设 $\{X_n\}, X$ 是概率空间 $(\Omega, \mathcal{A}, \mathbb{P})$ 中复值随机变量，且存在常数 $c > 0$，使得 $|X_n|, |X| \le c, \forall n \in \mathbb{N}$. 若 $X_n \to X$ *in prob.* 则 $\mathbb{E}|X_n - X| \to 0, n \to \infty$.

证明. $\forall \epsilon > 0$,

$$\begin{aligned}\mathbb{E}|X_n - X| &= \mathbb{E}[|X_n - X|\chi_{\{|X_n - X|\le\epsilon\}}] + \mathbb{E}[|X_n - X|\mathbf{1}_{\{|X_n - X|>\epsilon\}}] \\ &\le \epsilon + 2c \cdot P(|X_n - X| > \epsilon)\end{aligned}$$

$\Rightarrow \mathbb{E}(X_n - X) \to 0.$ □

回到原定理，由于 $\mu_n \to \mu$ weakly in prob, 故 $\forall f \in C_b(\mathbb{R}), \langle \mu_n, f\rangle \to \langle \mu, f\rangle$ in prob. 从而由引理，$\mathbb{E}\langle \mu_n, f\rangle \to \mathbb{E}\langle \mu, f\rangle$.

（能用引理是因为 $|\langle \mu_n, f\rangle| \le \|f\|_\infty, |\langle \mu, f\rangle| \le \|f\|_\infty$） □

1.14　笔记及习题解答: 随机矩阵理论/矩方法

原网页

问题：如何证明 ESD 的收敛？

定义 1.14.1. 设 μ 是 $(\mathbb{R},\mathcal{B})$ 上的测度，若 $\forall k=0,1,2,\ldots,\langle\mu,|x|^k\rangle<\infty$, 则 $m_k=\langle\mu,x^k\rangle$ 被称为是 μ 的 k 阶矩，且称 μ 具有有限的 k 阶矩。若 $\langle\mu,x^k\rangle=\infty$，则称 μ 的 k 阶矩不存在。

这里 $\langle\mu,x^k\rangle=\int x^k\,d\mu(x)$.

1.15　矩问题 (Hamburger 问题)

给定实数序列 $(m_k)_{k\in\mathbb{N}}$，是否存在唯一的 $(\mathbb{R},B)$ 上的测度 μ，使得 m_k 是 μ 的 k 阶矩？

1° 存在性

2° 唯一性

$$\begin{cases}\text{唯一} & \text{determinate}\\ \text{不唯一} & \text{indeterminate}\end{cases}$$

我们不加证明地给出如下两个定理：

定理 1.15.1. *(存在性刻画)* 一族实数列 $(m_k)_{k\in\mathbb{N}}$ 构成了 $(\mathbb{R},\mathcal{B})$ 上至少一个测度的矩 $\Leftrightarrow\forall N\in\mathbb{N}$, *Hankel* 矩阵

$$\begin{pmatrix} m_0 & m_1 & m_2 & \cdots & m_N\\ m_1 & m_2 & m_3 & \cdots & m_{N+1}\\ m_2 & m_3 & m_4 & \cdots & m_{N+2}\\ \vdots & \vdots & \vdots & \ddots & \vdots\\ m_N & m_{N+1} & m_{N+2} & \cdots & m_{2N}\end{pmatrix}$$

是半正定的。

定理 1.15.2. *(唯一性刻画)*

设 $(m_k)_{k\in\mathbb{N}}$ 是一族实数列，若下面三个条件中的任何一方满足，则最多存在 $(\mathbb{R},\mathcal{B})$ 上的一个测度以 m_k 为矩。

(1)

$$\sum_{k=1}^{\infty}(m_{2k})^{-\frac{1}{2k}}=\infty\quad(\textit{Carleman}\text{ 条件})$$

(2)

$$\limsup_{k\to\infty}\frac{(m_{2k})^{\frac{1}{2k}}}{2k}<\infty$$

(3) 存在 $C,D>0$，*s.t.* $\forall k\in\mathbb{N}$，$|m_k|\le CD^k k!$

注 1.15.1. *(2) ⇒ (1)*：令 $\alpha_k = (m_{2k})^{\frac{1}{2k}}$，$r := \limsup_{k\to\infty} \frac{\alpha_k}{2k} < \infty$。

$\Rightarrow \exists k_0 \in \mathbb{N}$，*s.t.* $k > k_0$，$\frac{\alpha_k}{2k} \le r+1$，即 $\alpha_k \le 2k(r+1)$。

$\Rightarrow \sum_{k=1}^{\infty} \frac{1}{\alpha_k} \ge \sum_{k=k_0}^{\infty} \frac{1}{2k(r+1)} = \infty$。

(3) ⇒ (2)：$\frac{(m_{2k})^{\frac{1}{2k}}}{2k} \le \frac{(CD^{2k}(2k)!)^{\frac{1}{2k}}}{2k} \le \frac{C^{\frac{1}{2k}} D((2k)!)^{\frac{1}{2k}}}{2k} \le C^{\frac{1}{2k}} D$

推论 1.15.1. 具有紧支撑的概率测度：设 ν 是 $(\mathbb{R}, \mathcal{B})$ 上的概率测度且有紧支撑 $[-a, a]$，$a > 0$。则：

(1) ν 具有各阶矩。

(2) $\forall k \in \mathbb{N}$，$|\langle \nu, x^k \rangle| \le a^k$。

(3) ν 由它的矩唯一决定。

1.16　概率测度的矩方法

定理 1.16.1. 设 $(\mu_n)_n$ 是 $\mathcal{M}_1(\mathbb{R})$ 中的一个序列且所有矩都存在。若存在一个实序列 $(m_k)_{k\in\mathbb{N}}$，*s.t.* $\forall k \in \mathbb{N}$,

$$\lim_{n\to\infty} \langle \mu_n, x^k \rangle = m_k$$

则 $\exists \mu \in \mathcal{M}_1(\mathbb{R})$ 以及 $(\mu_n)_n$ 中的子序列弱收敛到 μ，且有 $\langle \mu, x^k \rangle = m_k$。若 μ 由它的矩唯一决定，则整个序列弱收敛到 μ。

证明. 取 $k = 2$。由之前引理知 $(\mu_n)_{n\in\mathbb{N}}$ 是紧的，故

$$\exists \mu \in M_1(\mathbb{R}),\ J \subset \mathbb{N},\ \text{s.t. } (\mu_n)_{n\in J} \text{ 弱收敛到 } \mu.$$

取 $g = 1 + x^{2k}$，则由条件，$(\langle \mu, g \rangle)_{n\in J}$ 有界，且 $\frac{x^k}{g} \to 0,\ x \to \infty$. 由习题 4，$\langle \mu_n, x^k \rangle \to \langle \mu, x^k \rangle$，即 m_k 是 μ 的 k 阶矩。

若 μ 由它的矩唯一决定，设子序列中的另一子序列具有相同的弱极限，$\forall I \subset \mathbb{N}, \exists J' \subset I$，$v \in M_1(\mathbb{R})$，$(\mu_n)_{n\in J'} \to \nu$ 弱收敛，且 ν 以 m_k 为 k 阶矩。由于 m_k 决定唯一测度，故 $\mu = \nu$。 □

注 1.16.1. 该定理逆命题不成立。存在 $(\mu_n)_n$ 与 $\mu \in \mathcal{M}_1(\mathbb{R})$ 满足：

1. μ 的各阶矩存在

2. μ_n 弱收敛到 μ

3. $\langle \mu_n, x^k \rangle \to \langle \mu, x^k \rangle$ 不成立

取 $\mu_n = \frac{n-1}{n}\delta_0 + \frac{1}{n}\delta_{e^n}$，则 $\mu_n \xrightarrow{w} \mu$，其中 $\mu = \delta_0$。

对于任意 f，有

$$\langle \mu_n, f \rangle = \frac{n-1}{n} f(0) + \frac{1}{n} f(e^n) \to f(0) = \langle \mu, f \rangle.$$

对于矩，

$$\langle \mu_n, x^k \rangle = \frac{1}{n} e^{nk} \text{ 不趋于 } 0 = \langle \mu, f \rangle,\ n \to \infty,$$

1.17　随机概率测度的矩方法

定理 1.17.1. 设 $(\mu_n)_n$ 是 $(\mathbb{R},\mathcal{B})$ 上的随机概率测度，μ 是 $(\mathbb{R},\mathcal{B})$ 上的由它的矩唯一决定的概率测度。且假定下列论述中各量都是良定义且有限的。

(1) $\forall k\in\mathbb{N},\mathbb{E}\langle\mu_n,x^k\rangle\to\langle\mu,x^k\rangle$，则 y_n 依期望弱收敛到 μ。

(2) $\forall k\in\mathbb{N}$, 若 $\langle\mu_n,x^k\rangle$ 依概率收敛到 $\langle\mu,x^k\rangle$，则 μ_n 依概率弱收敛到 μ。

(3) $\forall k\in\mathbb{N},\langle\mu_n,x^k\rangle\to\langle\mu,x^k\rangle\quad\mathbb{P}\,a.s.$，则 $\mu_n\to\mu\quad w.a.s.$

证明. (1) μ_n 依期望弱收敛到 μ，即，$\mathbb{E}\mu_n\in\mathcal{M}_1(\mathbb{R})$ 弱收敛到 μ。由于 μ 由它的矩唯一决定，故只需证明 $\mathbb{E}\langle\mu_n,x^k\rangle\to\langle\mu,x^k\rangle$. 结合条件，只需证明 $\langle\mathbb{E}\mu_n,x^k\rangle=\mathbb{E}\langle\mu_n,x^k\rangle$, 这只需证明 $\mathbb{E}\mu_n$ 具有各阶矩。

由之前引理，对非负可测函数 f，$\langle\mathbb{E}\mu_n,f\rangle=\mathbb{E}\langle\mu_n,f\rangle$，故对 $f=x^{2k}$ 成立。

由柯西不等式，$\langle\mathbb{E}\mu_n,|x|^k\rangle^2\le\langle\mathbb{E}\mu_n,x^{2k}\rangle=\mathbb{E}\langle\mu_n,x^{2k}\rangle<\infty$, 故可得各阶矩的存在性。

(2) $\mu_n\xrightarrow{w}\mu$ in prob. 即 $\forall f\in C_b(\mathbb{R}),\langle\mu_n,f\rangle\to\langle\mu,f\rangle$ in prob. 这等价于对任何子列，都有几乎处处收敛的子列。

现在对某个子列 $J\subseteq\mathbb{N},\langle\mu_n,x^k\rangle_{n\in J}\to\langle\mu,x^k\rangle$ in prob, 则存在 $I\subseteq J,\Omega_1\subseteq\Omega,P(\Omega_1)=1,\forall\omega\in\Omega_1,\forall k\in\mathbb{N},\langle\mu_n(\omega),x^k\rangle\to\langle\mu(\omega),x^k\rangle$, 由概率测度的矩方法，$\Rightarrow\mu_n(\omega),n\in I$ 弱收敛到μ.

由于子列 J 是任意的，我们证明了对于任何子列，都存在几乎处处弱收敛的子列，这等价于 μ_n 依概率弱收敛到 μ.

(3)$\forall k\in\mathbb{N},\exists\Omega_k,P(\Omega_k)=1,s.t.\forall\omega\in\Omega_k,\langle\mu_n(\omega),x^k\rangle\to\langle\mu,x^k\rangle$.

令 $\hat{\Omega}=\bigcap_{k=1}^{\infty}\Omega_k\subseteq\Omega$. 则 $P(\hat{\Omega})=1$, 且有 $\forall\omega\in\hat{\Omega},\forall k,\langle\mu_n(\omega),x^k\rangle\to\langle\mu,x^k\rangle$ 故 $\mu_n(\omega)$ 弱收敛到 μ. 从而 $\mu_n\to\mu\quad w.a.s.$ □

定理 1.17.2. *(Practical version)* $(\mu_n)_n$ 为随机概率测度，$(m_k)_k$ 为实数序列，且在 $(\mathbb{R},\mathcal{B})$ 上至少存在一个概率测度以 m_k 为 k 阶矩。

(M1) $\mathbb{E}\langle\mu_n,x^k\rangle\to m_k$。$\forall k$，有分解

$$\langle\mu_n,x^k\rangle=D_n^{(k,1)}+\cdots+D_n^{(k,l_k)},$$

s.t. $\forall k,i=1,\ldots,l_k$，$\mathbb{E}D_n^{(k,i)}\to c_k$.

(M2) $\forall k\in\mathbb{N},i=1,\ldots,l_k$，$\exists z\in\mathbb{N}$，

$$\mathbb{E}\left(\left|D_n^{(k,i)}-\mathbb{E}D_n^{(k,i)}\right|^z\right)\xrightarrow{n\to\infty}0.$$

(M3) $\forall k,i$，$\exists z\in\mathbb{N}$，*s.t.*

$$\mathbb{E}\left(\left|D_n^{(k,i)}-\mathbb{E}D_n^{(k,i)}\right|^z\right)\to0\quad\text{可加快.}$$

我们有以下结论：

(M1) $\Rightarrow\exists\mu\in M_1(\mathbb{R})$，$\langle\mu,x^k\rangle=m_k$，*s.t.* $\mathbb{E}\mu_n$ 弱收敛到 μ（μ_n 依期望弱收敛到 μ）。

(M1) + (M2) $\Rightarrow\mu_n$ 依概率弱收敛到 μ。

(M1) + (M3) $\Rightarrow\mu_n$ 几乎处处弱收敛到 μ。

注 1.17.1. 可加快在这里指的是这个序列的和收敛。

引理 1.17.1. 设 $z \in \mathbb{N}, (Y_n)_n$ 是随机变量且 $\forall n, E(|Y_n|^2) < \infty$。若 $EY_n \to y$，且 $E(|Y_n - EY_n|^z) \to 0$，则 $Y_n \to y$ *in prob*。若 $E(|Y_n - EY_n|^z) \to 0$ 可求和，则 $Y_n \to y$ *a.s.*

证明. 由 Markov 不等式，

$$\begin{aligned} P(|\gamma_n - y| \geq \varepsilon) &= P(|\gamma_n - \mathbb{E}\gamma_n + \mathbb{E}\gamma_n - y| \geq \varepsilon) \\ &\leq P(|\gamma_n - \mathbb{E}\gamma_n| > \frac{\varepsilon}{2}) + P(|\mathbb{E}\gamma_n - y| > \frac{\varepsilon}{2}) \\ &\leq \left(\frac{\varepsilon}{2}\right)^{-z} \cdot \mathbb{E}(|\gamma_n - \mathbb{E}\gamma_n|^z) + P(|\mathbb{E}\gamma_n - y| > \frac{\varepsilon}{2}) \to 0. \end{aligned}$$

进一步，若 $\sum \mathbb{E}(|Y_n - \mathbb{E}Y_n|^z) < \infty$，则可证明 $\sum P(|Y_n - y| > \varepsilon) < \infty$，由 Borel-Cantelli 引理，$Y_n \to y$ a.s.

□

对定理的第二条和第三条，由引理，$D_n^{(k,i)} \to$ Const in prob / a.s. 故

$$\langle \mu_n, x^k \rangle = D_n^{(k,1)} + \cdots + D_n^{(k,l_k)} \implies m_k \quad \text{in prob / a.s.}$$

1.18　半圆分布和 MP 分布的矩

半圆分布 σ 的密度函数：$f_\sigma(x) = \frac{1}{2\pi}\sqrt{4 - x^2}$，$x \in [-2, 2]$. 对于其矩，我们有如下结论：$\forall k = 0, 1, 2, \cdots,$

$$\begin{cases} m_{2k}^\sigma = \frac{1}{2\pi}\int_{-2}^{2} \sqrt{4 - x^2} x^{2k}\, dx = \frac{(2k)!}{k!(k+1)!}, \\ m_{2k+1}^\sigma = 0. \end{cases}$$

习题 8. 证明半圆分布的矩有上述形式。

证明. 首先，由于 $f_\sigma(x)$ 是偶函数，而 x^{2k+1} 是奇函数，因此奇数阶矩为零：

$$m_{2k+1}^\sigma = \int_{-2}^{2} x^{2k+1} f_\sigma(x)\, dx = 0$$

对于偶数阶矩：

$$m_{2k}^\sigma = \frac{1}{2\pi}\int_{-2}^{2} x^{2k}\sqrt{4 - x^2}\, dx$$

由于被积函数是偶函数，可简化为：

$$m_{2k}^\sigma = \frac{1}{\pi}\int_{0}^{2} x^{2k}\sqrt{4 - x^2}\, dx$$

令 $x = 2\sin\theta$，则 $dx = 2\cos\theta\, d\theta$，当 x 从 0 到 2 时，θ 从 0 到 $\frac{\pi}{2}$：

$$m_{2k}^\sigma = \frac{1}{\pi}\int_{0}^{\frac{\pi}{2}} (2\sin\theta)^{2k}\sqrt{4 - 4\sin^2\theta} \cdot 2\cos\theta\, d\theta$$

$$= \frac{1}{\pi}\int_{0}^{\frac{\pi}{2}} 2^{2k}\sin^{2k}\theta \cdot 2\cos\theta \cdot 2\cos\theta\, d\theta = \frac{2^{2k+2}}{\pi}\int_{0}^{\frac{\pi}{2}} \sin^{2k}\theta\cos^2\theta\, d\theta$$

现在计算积分：

$$J_k = \int_0^{\frac{\pi}{2}} \sin^{2k}\theta\cos^2\theta\, d\theta = \int_0^{\frac{\pi}{2}} \sin^{2k}\theta(1-\sin^2\theta)\, d\theta = I_{2k} - I_{2k+2}$$

其中 $I_n = \int_0^{\frac{\pi}{2}} \sin^n\theta\, d\theta$。由 Wallis 公式：

$$I_{2k} = \frac{(2k-1)!!}{(2k)!!}\cdot\frac{\pi}{2}, \quad I_{2k+2} = \frac{(2k+1)!!}{(2k+2)!!}\cdot\frac{\pi}{2}$$

利用关系式 $(2k)!! = 2^k k!$ 和 $(2k-1)!! = \frac{(2k)!}{2^k k!}$，得：

$$I_{2k} = \frac{(2k)!}{2^{2k}(k!)^2}\cdot\frac{\pi}{2}, \quad I_{2k+2} = \frac{(2k+2)!}{2^{2k+2}((k+1)!)^2}\cdot\frac{\pi}{2}$$

化简 I_{2k+2}：

$$I_{2k+2} = \frac{(2k+2)(2k+1)(2k)!}{2^{2k+2}(k+1)^2(k!)^2}\cdot\frac{\pi}{2} = \frac{(2k+1)(2k)!}{2^{2k+1}(k+1)(k!)^2}\cdot\frac{\pi}{2}$$

于是：

$$J_k = I_{2k} - I_{2k+2} = \frac{\pi}{2}\cdot\frac{(2k)!}{2^{2k}(k!)^2}\left[1 - \frac{2k+1}{2(k+1)}\right] = \frac{\pi}{2}\cdot\frac{(2k)!}{2^{2k}(k!)^2}\cdot\frac{1}{2(k+1)} = \frac{\pi(2k)!}{2^{2k+2}k!(k+1)!}$$

代回原式：

$$m_{2k}^{\sigma} = \frac{2^{2k+2}}{\pi}\cdot J_k = \frac{2^{2k+2}}{\pi}\cdot\frac{\pi(2k)!}{2^{2k+2}k!(k+1)!} = \frac{(2k)!}{k!(k+1)!}$$

这正是卡特兰数 C_k 的表达式。可以验证此结果满足卡特兰数的递推关系：

$$\frac{C_k}{C_{k-1}} = \frac{\frac{(2k)!}{k!(k+1)!}}{\frac{(2k-2)!}{(k-1)!k!}} = \frac{(2k)(2k-1)}{k(k+1)} = \frac{2(2k-1)}{k+1}$$

因此，半圆分布的矩公式为：

$$m_{2k}^{\sigma} = \frac{(2k)!}{k!(k+1)!}, \quad m_{2k+1}^{\sigma} = 0$$

□

注 1.18.1. *(a)*σ 具有紧支集，故由矩唯一决定。

(b) Catalan 数：

$$C_k = \frac{(2k)!}{k!(k+1)!} = \binom{2k}{k} - \binom{2k}{k-1}$$

$$\Rightarrow m_k^{\sigma} = \begin{cases} C_{k/2}, & k \text{ even}, \\ 0, & k \text{ odd}. \end{cases}$$

MP 分布 $\mu^y, y>0, y_{\pm} = (1\pm\sqrt{y})^2$. 其密度函数为

$$f_{\mu^y}(x) = \frac{1}{2\pi xy}\sqrt{(y_+ - x)(x-y_-)}\chi_{[y_-,y_+]}(x) + \left(1-\frac{1}{y}\right)\delta_0\chi_{[y>1]}(x)$$

$$\text{其矩为} \quad \langle \mu^y, x^k\rangle = \sum_{r=0}^{k-1}\frac{y^r}{r+1}\binom{k}{r}\binom{k-1}{r}$$

1.19　RMT 中矩方法的应用

$(X_n)_n$：随机矩阵。

$(\sigma_n)_n$：经验谱分布。

$$\sigma_n = \frac{1}{n}\sum_{i=1}^{n}\delta_{\lambda_i}(X_n)$$

$$\begin{aligned}\langle\sigma_n, x^k\rangle &= \frac{1}{n}\sum_{i=1}^{n}\lambda_i^k(X_n) = \frac{1}{n}Tr(X_n^k)\\ &= \frac{1}{n}\sum_{t_1,\dots,t_k=1}^{n} X_n(t_1,t_2)X_n(t_2,t_3)\cdots X_n(t_k,t_1)\end{aligned}$$

定理 1.19.1. 设 $(\sigma_n)_n$ 是随机矩阵 $(X_n)_n$ 的经验谱分布，且 X_n 中各元素有各阶绝对矩 $\mathbb{E}(|X_n(i,j)|^p) < \infty$。若 $\forall k \in \mathbb{N}$，$\mathbb{E}\langle\sigma_n, x^k\rangle \to m_k$，且 $(m_k)_k$ 满足 *Carleman* 条件，则 σ_n 依期望弱收敛到 $\mu \in \mathcal{M}_1(\mathbb{R})$，且 $\langle\mu, x^k\rangle = m_k$。

证明这个定理只需说明 $\mathbb{E}\langle\sigma_n, x^k\rangle$ 有限。

引理 1.19.1. 设 $Y_1, \dots, Y_k$ 是取 $\mathbb{K}$ 值的随机变量，且 $\mathbb{E}(|Y_i|^k) < \infty$，则

$$\mathbb{E}(|Y_1Y_2\cdots Y_k|) \le \Big(\mathbb{E}(|Y_1|^k)\Big)^{1/k}\cdots\Big(\mathbb{E}(|Y_k|^k)\Big)^{1/k}.$$

证明. Cauchy–Schwarz 不等式 + 归纳法。 □

从而结合引理及

$$\langle\sigma_n, x^k\rangle = \frac{1}{n}\sum_{t_1,\dots,t_k=1}^{n} X_n(t_1,t_2)\cdots X_n(t_k,t_1).$$

可得 $\mathbb{E}\langle\sigma_n, x^k\rangle$ 有限。

定理 1.19.2. 设 $(\sigma_n)_n$ 是 *Hermite* 随机矩阵 $(X_n)_n$ 的经验谱分布，且 X_n 中所有元素具有各阶绝对矩。μ 是由 $(m_k)_k$ 唯一决定的概率测度。

(i) 假设 $\forall k \in \mathbb{N}$，存在分解：$\langle\sigma_n, x^k\rangle = D_n^{(k,1)} + \cdots + D_n^{(k,l_k)}$, 且 $\lim_{n\to\infty}\mathbb{E}D_n^{(k,i)}$ 存在。若 σ_n 依期望收敛到 μ，则 $\mathbb{E}\langle\sigma_n, x^k\rangle \to m_k$。

(ii) 若 *(i)* 成立，且 $\exists z \in \mathbb{N}$，$\mathbb{E}(|D_n^{(k,i)} - \mathbb{E}D_n^{(k,i)}|^z) \to 0$，则 $\mu_n \to \mu$ *in prob*。

(iii) 若 *(i)* 成立，且 $\exists z \in \mathbb{N}$，$\mathbb{E}(|D_n^{(k,i)} - \mathbb{E}D_n^{(k,i)}|^z) \to 0$ 可加快，则 $\mu_n \to \mu$ *a.s.*

1.20　笔记及习题解答: 随机矩阵理论/行列式点过程 (Determinantal Point Process)

原网页

1.21　点过程

定义 1.21.1. *$\mathcal{X}$ 称为配置 (configuration), 若它是实轴上一个子集, 且 $\#(\mathcal{X}\cap[a,b])<+\infty$, $[a,b]$ 是 $\mathbb{R}$ 上的有界区间, 一个配置可以有限, 也可以是可数无限且没有可数聚点.*

$\mathbb{R}$ 上的 (局部有限) 的点过程是所有配置构成空间上的概率测度.

一个点过程被称为 n-点过程, 若 $P(\#\mathcal{X}=n)=1$

例 1.21.1. *例: $P(x_1,\dots,x_n)$ 是 $\mathbb{R}^n$ 上关于 Lebesgue 测度的 pdf, 且关于坐标置换 (permutation) 不变, 即 $P(x_{\sigma(1)},\dots,x_{\sigma(n)})=P(x_1,\dots,x_n)$, 其中 $\sigma\in S_n$, 则这就定义了一个点过程.*

1.22　关联函数

给定了一个 $\mathbb{R}$ 上的点过程 P, $\forall\mathbb{R}$ 上的 Borel 集 $A\subset\mathbb{R}$, 映射 $A\longmapsto E(\#(\mathcal{X}\cap A))$ 是 $\mathbb{R}$ 上的测度, 这里的期望是关于点过程取的. 若进一步假设该测度关于 Lebesgue 测度具有密度函数 ρ_1, 则称 ρ_1 是强度 (intensity) 或 1-点关联函数. $\rho_1(x)dx$ 表示在 $[x,x+dx]$ 具有一个点的概率.

k-点关联函数记为 ρ_k，$\rho_k(x_1,\dots,x_k)dx_1\dots dx_k$，　$x_i\neq x_j, i\neq j$. 表示在每个无穷小区间 $[x_j,x_j+dx_j], j=1,\dots,k$ 有一个点的概率.

$$\begin{aligned}&\Rightarrow\int_A\dots\int_A\rho_k(x_1,\dots,x_k)dx_1\dots dx_k\\&=E(\prod_{j=1}^k\#(\mathcal{X}\cap A_k)),\quad A_j\text{ 互不相交}\end{aligned}$$

表示满足 $(x_1,\dots,x_k)\in\mathcal{X}^k, x_j\in A_j$ 的期望数目.

注 1.22.1. *(1) 若 $A_j=A$, 则*

$$\frac{1}{k!}\int_A\dots\int_A P_k(x_1,\dots,x_k)dx_1\dots dx_k$$

表示有序数组 $(x_1,\dots,x_k)$, $x_1<\dots<x_k$, $x_i\in A$ 的期望.

$\frac{1}{k!}\int_{\mathbb{R}^k}P(x_1,\dots,x_k)dx_1\dots dx_k=E\begin{pmatrix}\#(\mathcal{X}\cap A)\\k\end{pmatrix}$

(2) 若 $p(x_1,\dots,x_n)$ 是 $\mathbb{R}^n$ 上的概率密度函数, 且在坐标置换下保持不变, 则 p 对应点过程的 k-点关联函数

$\rho_k(x_1,\dots,x_k)=\frac{n!}{(n-k)!}\int_{\mathbb{R}}\dots\int_{\mathbb{R}}p(x_1,\dots,x_n)dx_{k+1}\dots dx_n$.

1.23　行列式点过程

定义 1.23.1. *$\mathbb{P}$ 是 $\mathbb{R}$ 上的关联函数为 ρ_k 的点过程, 该点过程被称为行列式点过程 (determinantal), 若存在核函数 $K(x,y)$, s.t. $\forall k$, 有 $\rho_k(x_1,\dots,x_k)=\det[K(x_i,x_j)]_{i,j=1}^k$. 核 K 被称为是行列式点过程的关联核 (Correlation Kernel).*

注 1.23.1. *(1) 关联核不唯一, 事实上对关联核做变换*

$$K(x,y)\to\frac{R(x)}{R(y)}k(x,y)\quad(R(x)\neq0).$$

则得到同一个 *DPP*.

(2) 在 *DPP* 中, 相邻点互相强排斥. 在物理文献中也被称为费米点过程.

定理 1.23.1. 设有核函数 K 满足条件 *(a)-(c):*

(a) $\int_{-\infty}^{\infty} K(x,x)dx = n$

(b) $\forall x_1,\dots,x_n \in \mathcal{R}$, 有 $\det(K(x_i,x_j))_{i,j=1}^n$ 非负定,

(c) 再生核 *(reproducing)*

$$\int_{-\infty}^{\infty} K(x,s)K(s,y)ds = K(x,y).$$

则 $P_n(x_1,\dots,x_n) = \frac{1}{n!}\det(K(x_i,x_j))_{i,j=1}^n$ 定义了 $\mathbb{R}^n$ 上的关于坐标置换不变的概率密度函数, 则其对应的 n 点过程是 *DPP* 且以 K 为关联核.

证明. P_n 对应的 DPP 的 k 点关联函数

$$\frac{n!}{(n-k)!}\int\cdots\int P(x_1,\dots,x_n)dx_{k+1}\dots dx_n$$

故现在只要验证

$$\int\cdots\int \det(K(x_i,x_j))_{i,j=1}^n dx_{k+1}\cdots dx_n = (n-k)!\det(K(x_i,x_j))_{i,j=1}^k$$

留做习题。 □

习题 3. 验证

$$\int\cdots\int \det(K(x_i,x_j))_{i,j=1}^n dx_{k+1}\cdots dx_n = (n-k)!\det(K(x_i,x_j))_{i,j=1}^k.$$

证明. 由习题 2 及 $\int_{-\infty}^{\infty} K(x,x)dx = n$，可得

$$\begin{aligned}\int\cdots\int \det(K(x_i,x_j))_{i,j=1}^n dx_{k+1}\cdots dx_n &= (n-n+1)\int\cdots\int \det(K(x_i,x_j))_{i,j=1}^{n-1} dx_{k+1}\cdots dx_{n-1}\\ &= \cdots\\ &= (n-k)!\det(K(x_i,x_j))_{i,j=1}^k\end{aligned}$$

□

1.24 Gap probability (间隙概率) & Fredholm determinant

给定 Borel 集 A 中没有点的概率.

$P_A(n)$: A 中仅有 n 个点的概率,

$P_A(0)$: gap probability.

$$\begin{aligned}\frac{1}{k!}\int_{A^k}\rho(x_1,\dots,x_k)dx_1\dots dx_k &= A \text{ 中有序 } k \text{ 元组个数的期望}\\ &= \sum_{n=k}^{\infty} P_A(n)\binom{n}{k}\end{aligned}$$

从而结合 $\sum_{k=0}^{n}(-1)^k\binom{n}{k}=\begin{cases}1 & n=0\\ 0 & n\neq 0\end{cases}$, 得到：

$$\begin{aligned}&\sum_{k=0}^{\infty}\frac{(-1)^k}{k!}\cdot\int_{A^k}P_k(x_1,\ldots,x_k)dx_1\ldots dx_k\\ =&\sum_{k=0}^{\infty}\sum_{n=k}^{\infty}(-1)^k\binom{n}{k}P_A(n)\\ =&\sum_{n=0}^{\infty}\left(\sum_{k=0}^{n}(-1)^k\binom{n}{k}\right)P_A(n)=P_A(0)\end{aligned}$$

当 ρ_k 是 DPP 时，则有：

$$P_A(0)=\sum_{k=0}^{\infty}\frac{(-1)^k}{k!}\int_{A^k}\det(K(x_i,x_j))_{i,j=1}^{k}dx_1\ldots dx_k=\det(I-K_A)$$

上式称为 Fredholm determinant.

其中算子 K_A 定义为：

$$\begin{aligned}K_A:L^2(A)&\to L^2(A)\\ f&\mapsto\int_A k(x,y)f(y)dy\end{aligned}$$

若 K_A 是迹算子 (trace class operator)，可以验证行列式是良定的。事实上，若 k 关于两个变量连续, A 有限, 可以验证 $\det(I-K_A)$ 中的级数绝对收敛.

1.25　DPP & non-intersecting path

考虑整数格点上的随机游走. Y_k: k 时刻的位置, $i\to i-1$ 的转移概率为 p_i, $i\to i+1$ 的为 q_i. 满足 $p_i+q_i=1$.

Q: n 条在 $t=0$ 时从不同 x_i 出发的路径不相交的概率?

定理 1.25.1. *(Karlin-McGregor) 考虑 n 个 Y_k, 即 $Y_k^{(1)},\cdots,Y_k^{(n)}$(表示 n 个路径), 满足 $Y_0^{(i)}=x_i$ $(x_1>x_2>\cdots>x_n)$.*

设 $t\in\mathbb{N}$ 及 $y_1>\cdots>y_n$.

记 $P_t(x_i,y_j)=P(Y_t=y_j|Y_0=x_i)$ (t 步从 X_i 到 y_j 的概率)

则路径不交的概率为

$$\begin{aligned}&P(Y_t^{(i)}=y_i,\quad 1\le i\le n,\quad Y_s^{(1)}>Y_s^{(2)}>\ldots>Y_s^{(n)},\forall 0\le s\le t)\\ =&\det(P_t(x_i,y_j))_{i,j=1}^{n}\end{aligned}$$

例 1.25.1. *Y_t: 对称随机游走*

$P_2(0,2)=\frac{1}{4}$, $P_2(0,-2)=\frac{1}{4}$, $P_2(0,0)=\frac{1}{2}$

考虑两个这样的随机游走: $x_1 = 2 = y_1$, $x_2 = 0 = y_2$

$$\begin{aligned} &P(Y_2^{(1)} = 2 = Y_0^{(1)}, Y_2^{(2)} = 0 = Y_0^{(2)}, Y_1^{(1)} > Y_1^{(2)}) \\ =& \det \begin{pmatrix} P_2(2,2) & P_2(2,0) \\ P_2(0,2) & P_2(0,0) \end{pmatrix} \\ =& \begin{vmatrix} \frac{1}{2} & \frac{1}{4} \\ \frac{1}{4} & \frac{1}{2} \end{vmatrix} = \frac{3}{16}. \end{aligned}$$

回到定理证明:

证明. Ω_{ij}: t 步由 x_i 到 y_j 的路径全体.

$P(\pi)$: $\pi \in \Omega_{ij}$, 取到这样一条路径的概率.

$P_t(x_i, y_j) = \sum_{\pi \in \Omega_{ij}} P(\pi)$

先考察 $n = 2$ 情形:

$$\begin{aligned} \det \begin{pmatrix} P_t(x_1,y_1) & P_t(x_1,y_2) \\ P_t(x_2,y_1) & P_t(x_2,y_2) \end{pmatrix} &= P_t(x_1,y_1)P_t(x_2,y_2) - P_t(x_1,y_2)P_t(x_2,y_1) \\ &= \sum_{\pi \in \Omega_{11}} P(\pi) \cdot \sum_{\sigma \in \Omega_{22}} P(\sigma) - \sum_{\pi \in \Omega_{12}} P(\pi) \sum_{\sigma \in \Omega_{21}} P(\sigma) \end{aligned}$$

标红部分表示 $x_1 \to y_1, x_2 \to y_2$ 的所有路径对求和，可以相交。

我们想求的是不相交的路径对的概率和。故希望标绿部分是所有相交路径的概率和。

事实上，由反射原理可得，$x_1 \to y_1, x_2 \to y_2$ 中的所有相交路径与 $x_1 \to y_2, x_2 \to y_1$ 的路径对有一个一一对应。从而标绿部分即为相交的概率和。从而 $n = 2$ 情形证毕。

对一般的 n，留做习题。

□

习题 4. 对一般的 n 证明定理 *5.1* 结论.

证明.

$$\det(P_t(x_i, y_j))_{i,j=1}^n = \sum_{\sigma \in S_n} \operatorname{sgn}(\sigma) \prod_{i=1}^n P_t(x_i, y_{\sigma(i)})$$

恒等映射对应全体 $(x_1 \to y_1, \ldots, x_n \to y_n)$ 的路径的概率和，其他映射均是相交情形。

记 Ω_{ij} 为从 x_i 到 y_j 的所有路径集合，则 $P_t(x_i, y_j) = \sum_{\pi \in \Omega_{ij}} P(\pi)$。

路径组 $(\pi_1, \ldots, \pi_n)$ 对应 $\sigma \in S_n$，即每个 π_i 表示 $x_i \to y_{\sigma(i)}$。

对任何相交路径组 $(\pi_1, \ldots, \pi_n)$，令 s 为最小非负时间，使得存在某个 i 满足 $Y_s^{(i)} \le Y_s^{(i+1)}$，且令该 i 为满足此式的最小一个。显然 $s \ge 1$.

定义新路径 $(\pi_1', \ldots, \pi_n')$:

- 对 $k \ne i, i+1$，有 $\pi_k' = \pi_k$
- 对 $r < s$，$\pi_i'(r) = \pi_i(r)$，$\pi_{i+1}'(r) = \pi_{i+1}(r)$
- 对 $r \ge s$，$\pi_i'(r) = \pi_{i+1}(r)$，$\pi_{i+1}'(r) = \pi_i(r)$

交换后，路径 π_i' 从 x_i 出发，到达 $y_{\sigma(i+1)}$；路径 π_{i+1}' 从 x_{i+1} 出发，到达 $y_{\sigma(i)}$。

从而新路径组对应排列 $\sigma\circ(i,i+1)$，故 $\text{sgn}(\sigma')=-\text{sgn}(\sigma)$。

易见新路径组仍相交（系路径一样，只是后半程交换）。记这个把相交路径映射到相交路径的映射为 φ。

则 $\varphi(\varphi(\pi))=\pi$，故我们构造了相交路径的一一配对。又由于 φ 改变 σ 的奇偶性，故相交路径组以正负贡献成对抵消。

因此 $\det(P_t(x_i,y_j))_{i,j=1}^n$ 只剩 $\sigma=\text{id}$ 中不相交路径的贡献，而 $\text{sgn}(\text{id})=+1$，故：$\det(P_t(x_i,y_j))_{i,j=1}^n$ 等于不相交路径的概率和，即：2

$$\det(P_t(x_i,y_j))_{i,j=1}^n=P(Y_t^{(i)}=y_i,1\le i\le n,Y_s^{(1)}>\cdots>Y_s^{(n)},\forall 0\le s\le t)$$

□

1.26　Tracy-Widom 分布

GUE: 无序特征值的分布。

$$P(y_1,\cdots,y_N)=\frac{1}{N!}\det(k_N(y_i,y_j))_{i,j=1}^N.$$

其中，$K_N(x,y)$ 为 Hermite 核，定义为：

$$K_N(x,y)=\sum_{k=0}^{N-1}\psi_k(x)\psi_k(y).$$

接下来，我们考虑最大特征值的分布问题。首先有：

$$P(\lambda_{\max}^{(N)}\le t)=P(\text{在}(t,+\infty)\text{ 中没有特征值})=\det(I-K_N|_{(t,+\infty)}).$$

进一步展开得到：

$$P(\lambda_{\max}^{(N)}\le t)=1+\sum_{r=1}^{N}\frac{(-1)^r}{r!}\int_t^{\infty}\cdots\int_t^{+\infty}\det(K_N(\mu_i,\mu_j))_{i,j=1}^r d\mu_1\cdots d\mu_r.$$

假设最大特征值的近似形式为：

$$\lambda_{\max}^{(N)}\approx 2\sqrt{N}+?.$$

在区间 $(2-t,2)$ 内，特征值的个数可以表示为：

$$N\int_{2-t}^{2}P(x)dx=\frac{N}{2\pi}\int_{2-t}^{2}\sqrt{4-x^2}dx.$$

令上式量级为 $O(1)$, 由此可以得到：

$$t=O(N^{-\frac{2}{3}}),$$

因此，最大特征值的表达式写为：

$$\lambda_{\max}^{(N)}=\sqrt{N}\left(2+tN^{-\frac{2}{3}}\right)=2\sqrt{N}+tN^{-\frac{1}{6}}.(t\text{ 是}r.v)$$

做一个尺度化：

$$令\tilde{K}_N(x,y)=N^{-\frac{1}{6}}K_N(2\sqrt{N}+xN^{-\frac{1}{6}},2\sqrt{N}+yN^{-\frac{1}{6}}).$$

则

$$P\left(\left(\lambda_{\max}^{(N)}-2\sqrt{N}\right)N^{\frac{1}{6}}\le t\right)=\sum_{r=0}^{N}\frac{(-1)^r}{r!}\int_t^{\infty}\cdots\int_t^{\infty}\det(\tilde{k}_N(x_i,y_j))_{i,j=1}^{r}dx_1\cdots dx_r.$$

当 $N\to+\infty$ 时，这个概率分布会收敛到一个极限分布 $F_2(t)$. 这就是 TW 分布。

接下来，我们考虑 Hermite 核 $K_N(x,y)$ 的表达式：

$$K_N(x,y)=\frac{1}{\sqrt{2\pi}}\sum_{k=0}^{N-1}\frac{1}{k!}e^{-\frac{1}{4}(x^2+y^2)}H_k(x)H_k(y),$$

其中 $H_k(x)$ 是 Hermite 多项式。通过应用 Christoffel-Darboux 公式, 即：

$$\sum_{k=0}^{N-1}\frac{H_k(x)H_k(y)}{k!}=\frac{H_N(x)H_{N-1}(y)-H_{N-1}(x)H_N(y)}{(x-y)(N-1)!}.$$

将核函数表示为：

$$\begin{aligned}K_N(x,y)&=\frac{1}{\sqrt{2\pi}}e^{-\frac{x^2+y^2}{4}}\frac{H_N(x)H_{N-1}(y)-H_{N-1}(x)H_N(y)}{(x-y)(N-1)!}\\&=\sqrt{N}\frac{\Psi_N(x)\Psi_{N-1}(y)-\Psi_{N-1}(y)\Psi_N(x)}{x-y}\\&=\frac{\Psi_N(x)\Psi_N'(y)-\Psi_N'(x)\Psi_N(y)}{x-y}-\frac{1}{2}\Psi_N(x)\Psi_N(y)\end{aligned}$$

其中用到 $\Psi_N'(x)=-\frac{x}{2}\Psi_N(x)+\sqrt{N}\Psi_{N-1}(x)$.

习题 5. H_n 的定义见习题 *1* 处。

$$\psi_n(x)=\frac{1}{(2\pi)^{1/4}\sqrt{n!}}H_n(x)e^{-x^2/4},\qquad K_N(x,y)=\sum_{k=0}^{N-1}\psi_k(x)\psi_k(y).$$

(a) 证明：

$$\sum_{k=0}^{N-1}\frac{H_k(x)H_k(y)}{k!}=\frac{H_N(x)H_{N-1}(y)-H_N(y)H_{N-1}(x)}{(N-1)!\,(x-y)}.$$

(b) 利用 *(a)* 和 ψ_k 的定义，证明：

$$\begin{aligned}K_N(x,y)&=\frac{1}{\sqrt{2\pi}}e^{-(x^2+y^2)/4}\,\frac{H_N(x)H_{N-1}(y)-H_N(y)H_{N-1}(x)}{(N-1)!\,(x-y)}\\&=\sqrt{N}\frac{\psi_N(x)\psi_{N-1}(y)-\psi_{N-1}(x)\psi_N(y)}{x-y}.\end{aligned}$$

(c) 证明：

$$\psi_N'(x)=-\frac{x}{2}\psi_N(x)+\sqrt{N}\,\psi_{N-1}(x),\qquad N\ge 1.$$

证明. (a) 令 $S_N(x,y)=\sum_{k=0}^{N-1}\frac{H_k(x)H_k(y)}{k!}$，其中 $H_n(x)$ 是 Hermite 多项式，满足递推关系：

$$H_{n+1}(x)=xH_n(x)-nH_{n-1}(x),\quad n\ge 1,\tag{1.3}$$

且 $H_0(x)=1, H_1(x)=x$。考虑 $(x-y)S_N(x,y)$，对每一项使用递推关系：

$$(x-y)\frac{H_k(x)H_k(y)}{k!}=\frac{xH_k(x)H_k(y)-yH_k(x)H_k(y)}{k!}.$$

由递推关系，$xH_k(x)=H_{k+1}(x)+kH_{k-1}(x)$，$yH_k(y)=H_{k+1}(y)+kH_{k-1}(y)$，代入得：

$$\begin{aligned}(x-y)\frac{H_k(x)H_k(y)}{k!}&=\frac{1}{k!}\big[(H_{k+1}(x)+kH_{k-1}(x))H_k(y)-H_k(x)(H_{k+1}(y)+kH_{k-1}(y))\big]\\&=\frac{H_{k+1}(x)H_k(y)-H_k(x)H_{k+1}(y)}{k!}+\frac{H_{k-1}(x)H_k(y)-H_k(x)H_{k-1}(y)}{(k-1)!}.\end{aligned}$$

对 $k=0$ 到 $N-1$ 求和。注意当 $k=0$ 时第二项视为零。记

$$\begin{aligned}A&=\sum_{k=0}^{N-1}\frac{H_{k+1}(x)H_k(y)-H_k(x)H_{k+1}(y)}{k!},\\B&=\sum_{k=1}^{N-1}\frac{H_{k-1}(x)H_k(y)-H_k(x)H_{k-1}(y)}{(k-1)!}.\end{aligned}$$

在 B 中令 $j=k-1$，则 $j=0,\dots,N-2$，且

$$B=\sum_{j=0}^{N-2}\frac{H_j(x)H_{j+1}(y)-H_{j+1}(x)H_j(y)}{j!}.$$

于是

$$\begin{aligned}(x-y)S_N(x,y)&=A+B\\&=\sum_{j=0}^{N-1}\frac{H_{j+1}(x)H_j(y)-H_j(x)H_{j+1}(y)}{j!}+\sum_{j=0}^{N-2}\frac{H_j(x)H_{j+1}(y)-H_{j+1}(x)H_j(y)}{j!}.\end{aligned}$$

当 $j=0,\dots,N-2$ 时，两项相互抵消。仅剩 $j=N-1$ 时第一项的贡献：

$$(x-y)S_N(x,y)=\frac{H_N(x)H_{N-1}(y)-H_{N-1}(x)H_N(y)}{(N-1)!}.$$

因此，

$$S_N(x,y)=\frac{H_N(x)H_{N-1}(y)-H_N(y)H_{N-1}(x)}{(N-1)!\,(x-y)}.$$

这正是所求。

(b) 由 ψ_k 的定义：

$$\psi_k(x)=\frac{1}{(2\pi)^{1/4}\sqrt{k!}}H_k(x)e^{-x^2/4},$$

得

$$K_N(x,y)=\sum_{k=0}^{N-1}\psi_k(x)\psi_k(y)=\frac{e^{-(x^2+y^2)/4}}{\sqrt{2\pi}}\sum_{k=0}^{N-1}\frac{H_k(x)H_k(y)}{k!}.$$

利用 (a) 的结果：

$$K_N(x,y)=\frac{1}{\sqrt{2\pi}}e^{-(x^2+y^2)/4}\frac{H_N(x)H_{N-1}(y)-H_N(y)H_{N-1}(x)}{(N-1)!\,(x-y)}.$$

另一方面，计算

$$\begin{aligned}&\psi_N(x)\psi_{N-1}(y)-\psi_{N-1}(x)\psi_N(y)\\&=\frac{1}{\sqrt{2\pi}\sqrt{N!\,(N-1)!}}\big(H_N(x)H_{N-1}(y)-H_{N-1}(x)H_N(y)\big)e^{-(x^2+y^2)/4}.\end{aligned}$$

因此，

$$\begin{aligned}&\sqrt{N}\,\frac{\psi_N(x)\psi_{N-1}(y)-\psi_{N-1}(x)\psi_N(y)}{x-y}\\&=\frac{\sqrt{N}}{\sqrt{2\pi}\sqrt{N!\,(N-1)!}}\frac{H_N(x)H_{N-1}(y)-H_{N-1}(x)H_N(y)}{x-y}e^{-(x^2+y^2)/4}\\&=\frac{1}{\sqrt{2\pi}\,(N-1)!}\frac{H_N(x)H_{N-1}(y)-H_N(y)H_{N-1}(x)}{x-y}e^{-(x^2+y^2)/4},\end{aligned}$$

其中用到了 $\sqrt{N!\,(N-1)!}=\sqrt{N}\,(N-1)!$。这与 $K_N(x,y)$ 的表达式一致，故

$$K_N(x,y)=\sqrt{N}\,\frac{\psi_N(x)\psi_{N-1}(y)-\psi_{N-1}(x)\psi_N(y)}{x-y}.$$

(c) 令 $C_N=\dfrac{1}{(2\pi)^{1/4}\sqrt{N!}}$，则 $\psi_N(x)=C_NH_N(x)e^{-x^2/4}$。求导得

$$\psi_N'(x)=C_N\big(H_N'(x)e^{-x^2/4}+H_N(x)e^{-x^2/4}\cdot\Big(-\frac{x}{2}\Big)\big)=C_Ne^{-x^2/4}\big(H_N'(x)-\frac{x}{2}H_N(x)\big).$$

又

$$\begin{aligned}-\frac{x}{2}\psi_N(x)+\sqrt{N}\psi_{N-1}(x)&=-\frac{x}{2}C_NH_N(x)e^{-x^2/4}+\sqrt{N}C_{N-1}H_{N-1}(x)e^{-x^2/4}\\&=e^{-x^2/4}\big(-\frac{x}{2}C_NH_N(x)+\sqrt{N}C_{N-1}H_{N-1}(x)\big).\end{aligned}$$

比较两式，只需证明

$$C_NH_N'(x)=\sqrt{N}C_{N-1}H_{N-1}(x).$$

计算系数比：$\dfrac{C_{N-1}}{C_N}=\dfrac{\sqrt{N!}}{\sqrt{(N-1)!}}=\sqrt{N}$，故等价于

$$H_N'(x)=NH_{N-1}(x).$$

这正是 Hermite 多项式的导数性质，可由递推关系或直接验证得到。因此，对 $N\geq 1$ 有

$$\psi_N'(x)=-\frac{x}{2}\psi_N(x)+\sqrt{N}\psi_{N-1}(x).$$

□

然后，我们引入标准化后的函数 $\tilde{\Psi}_N(x)$，其定义为：

$$\tilde{\Psi}_N(x)=N^{\frac{1}{2}}\Psi_N(2\sqrt{N}+xN^{-\frac{1}{6}}).$$

则

$$\tilde{\Psi}_N'(x)=N^{\frac{1}{3}}\Psi_N'(2\sqrt{N}+xN^{-\frac{1}{6}}).$$

$$\tilde{k}_N(x,y)=\frac{\tilde{\psi}_N(x)\tilde{\psi}'_N(y)-\tilde{\psi}'_N(x)\tilde{\psi}_N(y)}{x-y}-\frac{1}{2N^{-\frac{1}{3}}}\tilde{\psi}_N(x)\tilde{\psi}_N(y).$$

接着，我们讨论当 $N\to\infty$ 时的极限行为。我们有以下事实：

$$\lim_{N\to\infty}\tilde{\Psi}_N(x)=A_i(x),$$
$$\lim_{N\to\infty}\tilde{\Psi}'_N(x)=A'_i(x)$$

其中 $A_i(x)$ 满足 Airy 方程：

$$A''_i(x)=xA_i(x).$$

在 $x\to+\infty$ 时，$A_i(x)$ 的渐近形式为：

$$A_i(x)\sim\frac{1}{2\sqrt{\pi}}x^{-\frac{1}{4}}\exp\left(-\frac{2}{3}x^{\frac{3}{2}}\right).$$

因此，极限核函数为：

$$\lim_{N\to\infty}\tilde{k}_N(x,y)=\frac{A_i(x)A'_i(y)-A'_i(x)A_i(y)}{x-y},$$

称之为 Airy kernel .

我们体会一下 $\lim\limits_{N\to\infty}\tilde{\Psi}_N(x)=A_i(x)$: 计算可得

$$\Psi''_N(x)+(N+\frac{1}{2}-\frac{x^2}{4})\Psi_N(x)=0.$$

由于

$$\begin{aligned}
&\tilde{\Psi}_N(x)=N^{\frac{1}{12}}\Psi_N(2\sqrt{N}+xN^{-\frac{1}{6}}),\\
\Rightarrow\tilde{\psi}''_N(x)&=-N^{-\frac{1}{4}}\left(N+\frac{1}{2}-\frac{(2\sqrt{N}+xN^{-\frac{1}{6}})^2}{4}\right)\Psi_N(2\sqrt{N}+xN^{-\frac{1}{6}})\\
&=-N^{-\frac{1}{3}}\left(\frac{1}{2}-\frac{4xN^{\frac{1}{3}}+x^2N^{-\frac{1}{3}}}{4}\right)\tilde{\Psi}_N(x)\\
&\approx x\tilde{\Psi}_N(x)\quad(N\to+\infty)
\end{aligned}$$

这和 Airy 函数满足的微分方程相同。

我们还有以下结论：

定理 1.26.1. 随机变量 $N^{\frac{2}{3}}(\lambda_{\max}(A_N)-2)$ 在 $N\to\infty$ 时, 有极限分布

$$\begin{aligned}
F_2(t)&=\lim_{N\to+\infty}P(N^{\frac{2}{3}}(\lambda_{\max}(A_N)-2)\le t)\\
&=\sum_{r=0}^{\infty}\frac{(-1)^r}{r!}\int_t^{\infty}\cdots\int_t^{\infty}\det(K_{A_i}(x_i,y_j))_{i,j=1}^r dx_1\cdots dx_r\\
&=\det(I-K_{Ai}|_{(t,+\infty)})
\end{aligned}$$

定理 1.26.2.

$$F_2(t)=\exp\left(-\int_t^{\infty}(x-t)q^2(x)\,dx\right),$$

其中 $q(x)$ 满足 *Painlevé II* 方程：

$$q''(x)=2q^3(x)-xq(x).$$

当 $x\to\infty$ 时，$q(x)\sim A_i(x)$。

1.27　笔记及习题解答: 随机矩阵理论/随机矩阵的极限律

原网页

1.28　随机矩阵的定义及基本性质

设 $\mathbb{K}=\mathbb{R}$ 或 $\mathbb{C}$。

$(\text{Mat}_n(K),\|\cdot\|_{\text{op}})$：取 $\mathbb{K}$ 值的的 n 维矩阵空间。

$$\forall X\in \text{Mat}_n(\mathbb{K}),\quad \|X\|_{\text{op}}=\sup\{\|Xv\|,v\in\mathbb{K}^n,\|v\|=1\}.$$

这里 $\|\cdot\|$：$\mathbb{K}^n$ 上的范数，$\|\cdot\|_{\text{op}}$：算子范数。

$$X_m\to X,\ m\to\infty,\text{即}\quad X_m(i,j)\to X(i,j),\ m\to\infty$$

X^* 为 X 的伴随 (adjoint)（当 $\mathbb{K}=\mathbb{R}$ 时，$X^*=X^T$；当 $\mathbb{K}=\mathbb{C}$ 时，$X^*=(\bar{X})^T$）。

若 $X=X^*$，则称 X 为自伴的 (self adjoint)。

$\text{SMat}_n(\mathbb{K})$：$\text{Mat}_n(\mathbb{K})$ 中自伴矩阵全体，是 $Mat_n(\mathbb{K})$ 中的闭子集。

定义迹运算：$\forall X\in\text{Mat}_n(\mathbb{K}),\quad Tr(X)=\sum_{t=1}^{n}X(t,t).$

引理 1.28.1. *迹运算在是 $(Mat_n(\mathbb{K}),\|\cdot\|_{op})$ 中的连续线性泛函，且满足以下性质：*

$$\forall X,S\in Mat_n(\mathbb{K}),\quad S\text{ 可逆},\quad Tr(X)=Tr(SXS^{-1})$$

引理 1.28.2. *$\forall X\in SMat_n(\mathbb{K})$，存在可逆矩阵 S，使得*

$$X=S\,diag(\lambda_1^*,\dots,\lambda_n^*)S^{-1},\quad \text{其中}\lambda_1^*\le\cdots\le\lambda_n^*.$$

定理 1.28.1. *$\forall n\in\mathbb{N}$，$X,Y\in SMat_n(\mathbb{K})$，有*

$$\sum_{i=1}^{n}(\lambda_i^X-\lambda_i^Y)^2\le Tr[(X-Y)^*(X-Y)]=Tr[(X-Y)^2]$$

推论 1.28.1. *$n\in\mathbb{N}$，$l\in\{1,\dots,n\}$，映射*

$$\begin{aligned}Eig_l:SMat_n(\mathbb{K})&\to\mathbb{R}\\X&\mapsto\lambda_X^l\end{aligned}$$

是连续的。

证明. 设 (X_m) 和 X 是 $\text{SMat}_n(\mathbb{K})$ 中的元素，且 $X_m\xrightarrow{m\to\infty}X$, 则

$$|\lambda_l^{X_m}-\lambda_l^X|^2\le\sum_{l=1}^{n}|\lambda_l^{X_m}-\lambda_l^X|^2\le Tr(X_m-X)^2\xrightarrow{m\to\infty}0$$

□

定义 1.28.1. $(\Omega, \mathcal{A}, \mathbb{P})$ 是概率空间，$n \in \mathbb{N}$。则一个 n 阶自伴随机矩阵是一个可测映射

$$X : (\Omega, \mathcal{A}) \to (SMat_n(\mathbb{K}), \mathcal{B}_S^{(n^2)})$$

这里 $\mathcal{B}_S^{(n^2)}$ 表示 $SMat_n(\mathbb{K})$ 上的 *Borel* σ-代数。

注 1.28.1. 映射可测 $\Leftrightarrow$ 每个 $X(i,j) : (\Omega, \mathcal{A}) \to (\mathbb{K}, \mathcal{B})$ 可测。

今后提及“随机矩阵”不加强调时一般均表示自伴随机矩阵。

若 X 是 $(\Omega, \mathcal{A}, \mathbb{P})$ 上的随机矩阵，则 $\forall \omega \in \Omega$，$X(\omega) \in \mathrm{SMat}_n(K)$，且有特征值 $\lambda_1^{X(\omega)} \leq \ldots \leq \lambda_n^{X(\omega)}$.

引理 1.28.3. X 是 $(\Omega, \mathcal{A}, \mathbb{P})$ 上的 n 阶随机矩阵，则映射

$$\begin{aligned} \lambda_i^X : (\Omega, \mathcal{A}) &\to (\mathbb{R}, \mathcal{B}) \\ \omega &\mapsto \lambda_i^{X(\omega)} \end{aligned}$$

是可测的，即 λ_l^X 是实值随机变量。

证明. $Eig_l : \mathrm{SMat}_n(\mathbb{K}) \to \mathbb{R}, X \mapsto \lambda_l^X$ 连续，而 $X : \Omega \to \mathrm{SMat}_n(\mathbb{K})$ 可测. 故二者复合 $\lambda_l^X = \mathrm{Eig}_l \circ X$ 可测.

□

1.29　特征值的经验分布 (empirical distribution)

定义 1.29.1. X 是 $(\Omega, \mathcal{A}, \mathbb{P})$ 上的 n 阶随机矩阵，则 X 的经验谱分布 *(ESD)* 是 $(\mathbb{R}, \mathcal{B})$ 上的随机概率测度：

$$\begin{aligned} \sigma_n : \Omega \times \mathcal{B} &\to [0,1] \\ (\omega, B) &\mapsto \sigma_n(\omega, B) = \frac{1}{n} \sum_{i=1}^{n} \delta_{\lambda_i^{X(\omega)}}(B) \end{aligned}$$

$\sigma_n(I)$ 表示 n 个特征值落在区间 I 中的比例。

1.29.1　Wigner 半圆律

定义 1.29.2. *(Wigner semicircle law)*

半圆分布 σ 是 $(\mathbb{R}, \mathcal{B})$ 中的概率测度且

$$d\sigma(x) = \frac{1}{2\pi} \sqrt{4 - x^2}\, dx, \quad x \in [-2, 2]$$

定义 1.29.3. 设 σ_n 是随机矩阵 $(X_n)_n$ 的 *ESD*，若

$$\begin{aligned} &\sigma_n \to \sigma \quad \textit{weakly in expectation;} \\ &\sigma_n \to \sigma \quad \textit{weakly in prob;} \\ &\sigma_n \to \sigma \quad \textit{weakly a.s,} \end{aligned}$$

则称半圆律对 σ_n 依期望/概率/*a.s* 成立。

定义 1.29.4. *(Wigner 矩阵)*
$W_n = \left(\frac{1}{\sqrt{n}}X_n(i,j)\right)_{i,j=1}^{n}$, 若 $X_n(i,j)$ 满足
(1) 具有一致有界的绝对矩：

$$\forall q \in \mathbb{N}, \exists L_q < \infty, \ s.t. \ \mathbb{E}(|X_n(i,j)|^q) < L_q.$$

(2) 随机变量是标准化的：$\mathbb{E}(X_n(i,j)) = 0, Var(X_n(i,j)) = 1.$
(3) $X_n^T = X_n$
(4) 独立性：随机变量 $X_n(i,j)$ *(*$i \le j$*)* 都是独立的。
则 W_n 称为 *Wigner* 矩阵。

定理 1.29.1. 半圆律对 *Wigner* 矩阵 *a.s.* 成立。

1.29.2 Marchenko-Pastur 律

设 $\vec{x}_i$ 为 p 维列向量 (p 为特征的个数)，$i = 1, \ldots, n.$
我们的数据矩阵为：

$$X_n = (\vec{x}_1, \cdots, \vec{x}_n)_{p\times n}$$

记 $\vec{x} = \frac{1}{n}\sum_{i=1}^{n}\vec{x}_i$. 样本协方差矩阵为：

$$\begin{aligned}\tilde{s}_n &:= \frac{1}{n-1}\sum_{k=1}^{n}(\vec{x}_k - \vec{x})(\vec{x}_k - \vec{x})^\top \\ &= \frac{n}{n-1}\left(\frac{1}{n}\sum_{k=1}^{n}\vec{x}_k\vec{x}_k^T - \vec{x}\vec{x}^T\right)\end{aligned}$$

假定样本取自 $\mathbb{R}^p$ 值随机向量 X，则 $\tilde{s}_n$ 是协方差矩阵

$$\mathbb{E}\left((X - \mathbb{E}X)(X - \mathbb{E}X)^T\right) = \begin{pmatrix} Var(X^{(1)}) & \cdots & Cov(X^{(1)}, X^{(p)}) \\ \vdots & \ddots & \vdots \\ Cov(X^{(p)}, X^{(1)}) & \cdots & Var(X^{(p)}) \end{pmatrix}$$

的无偏估计。

设 $p = p_n$，满足 $\frac{p_n}{n} \to y$*(*这非常重要*).*

定义 1.29.5. *(Marchenko-Pastur 分布)*

$$d_\mu y = \frac{1}{2\pi xy}\sqrt{((1+\sqrt{y})^2 - x)(x - (1-\sqrt{y})^2)}\chi_{[0,+\infty)}dx + (1 - \frac{1}{y})\delta_0 \ \chi_{\{y>1\}}$$

定义 1.29.6. *(MP 矩阵)*
若$V_n = \frac{1}{n}X_nX_n^T$, 其中 $X_n = (X_n(i,j))_{i\in[p],j\in[n]}$ 且 $X_n(i,j)$ 满足：
(1) 具有有界的绝对矩

$$\forall q, \exists L_q \ge 0, \ s.t. \ \mathbb{E}\left(|X_n(i,j)|^q\right) \le L_q$$

(2) 标准化

$$\mathbb{E}\left(X_n(i,j)\right)=0,\quad Var\left(X_n(i,j)\right)=1$$

(3) 独立性

$$X_n(i,j),\quad i\in[p],j\in[n]\quad \text{独立}$$

(4) $\frac{p_n}{n}\to y,\quad n\to\infty$

定理 1.29.2. $(V_n)_n$ 的 *ESD* 几乎处处弱收敛于 *MP* 律。

1.30　笔记及习题解答: 随机矩阵理论/高斯随机阵的解析分布

原网页

1.31　随机矩阵的定义方式

1. 给定具体元素的具体分布。
2. 给定一个矩阵空间，在空间上赋予一定测度。

1.32　Gaussian Orthogonal Ensemble, GOE

定义 1.32.1 (GOE 的两种等价定义). *(一)* 矩阵 A_N 是 $N\times N$ 的实对称矩阵 $(A_N^T=A_N)$。其元素 $A_N(i,j)$ $(i\le j)$ 是相互独立的、均值为 0 的正态分布随机变量，方差为：

$$Var(A_N(i,j))=\begin{cases}1/N, & i<j\\ 2/N, & i=j\end{cases}$$

(二) 在 N 阶实对称矩阵的空间 Ω_N 上，赋予如下的概率测度：

$$d\mathbb{P}_N(A_N)=C_N\exp\left(-\frac{N}{4}\operatorname{tr}(A_N^2)\right)\prod_{i\le j}dx_{ij}$$

其中 C_N 是归一化常数。

注 1.32.1.　*a)* 该测度在正交变换下不变。记 O 为正交阵 $(OO^T=I_N)$，对于变换 $B=OAO^T$，有

$$\operatorname{Tr}(B^2)=\operatorname{Tr}(OAO^TOAO^T)=\operatorname{Tr}(OA^2O^T)=\operatorname{Tr}(O^TOA^2)=\operatorname{Tr}(A^2).$$

进而有 $dB=dA$。

b) 对于 $N=2$, $A=\begin{pmatrix}x_{11}&x_{12}\\ x_{12}&x_{22}\end{pmatrix}$。第二种定义给出的分布（忽略常数）为

$$\begin{aligned}\exp(-\frac{1}{2}\operatorname{Tr}A^2)&=\exp(-\frac{1}{2}(x_{11}^2+2x_{12}^2+x_{22}^2))\\ &=\exp(-\frac{x_{11}^2}{2})\exp(-x_{12}^2)\exp(-\frac{x_{22}^2}{2})\end{aligned}$$

这与第一种定义中各元素独立的方差设定是相符的。一般情形类似可推得，故在 *Gaussian* 情形下，两种定义等价。

1.33　高斯酉系综 (Gaussian Unitary Ensemble, GUE)

定义 1.33.1 (GUE). 矩阵 $A_N = (a_{ij})$ 是 $N \times N$ 的复厄米矩阵 $(A_N^* = A_N)$ $(a_{ij} = \overline{a_{ji}})$。其中 $a_{ij} = x_{ij} + iy_{ij}$ $(i < j)$ 和 $a_{ii} = x_{ii}$ 的实部和虚部是 *i.i.d* 的高斯随机变量，且 $E(|a_{ij}|^2) = 1/N$。其概率测度为：

$$d\mathbb{P}(A_N) = C_N \exp\left(-\frac{N}{2}\operatorname{Tr}(A_N^2)\right) dA_N$$

其中 $dA_N = \prod_{i=1}^{N} dx_{ii} \prod_{i<j} dx_{ij} dy_{ij}$.

注 1.33.1.　*a) GUE* 的概率分布在酉变换 $(A \to U^*AU)$ 下不变。

b) 更一般的概率测度可以定义为

$$\frac{1}{Z_N} \exp(-N \operatorname{Tr} V(M)) dM,$$

其中 $V(M)$ 称为势函数，Z_N 称为配分函数 *(partition function)*。

- 对于一般的 V, 可以定义一个能量泛函

$$E(\mu) = \iint \log|x-y| d\mu(x) d\mu(y) + \int V(x) d\mu(x).$$

通过求解其极小值问题（平衡测度问题）可以得到 $N \to \infty$ 时的极限分布。以上仅是大致叙述，详细论述本课程不做讨论。

1.34　GUE 和 GOE 特征值分布的解析表达式

任何厄米/对称矩阵可以被对角化，$A_N = U^*DU$ (或 O^TDO)，其中 $D = \operatorname{diag}(\lambda_1, \ldots, \lambda_N)$。

例 1.34.1 (考查 GOE(2) 以体会特征值分布). $A = \begin{pmatrix} x_{11} & x_{12} \\ x_{12} & x_{22} \end{pmatrix}$，其概率密度为 $P(A) = C_2 \exp(-\frac{1}{2}\operatorname{Tr} A^2)$。

进行变量代换 $A = O^TDO$，其中 $D = \begin{pmatrix} \lambda_1 & \\ & \lambda_2 \end{pmatrix}$，$O = \begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix}$。由此可得 x_{ij} 与 $(\lambda_1, \lambda_2, \theta)$ 的关系。

取 $\lambda_1 < \lambda_2$,　$\cos\theta \geq 0$,　$\theta \in (-\pi/2, \pi/2)$，则可求得 x_{ij} 与新参数的变量代换关系。

计算得到变换的雅可比行列式为 $\det J = -(\lambda_1 - \lambda_2)$。因此，新的联合概率密度函数为：

$$q(\lambda_1, \lambda_2, \theta) = P(A(\lambda, \theta))|\det J| = C_2 \exp(-\frac{1}{2}(\lambda_1^2 + \lambda_2^2))|\lambda_1 - \lambda_2|.$$

该密度与 θ 无关。对任意函数 $f(\lambda_1, \lambda_2)$，其期望为：

$$E[f] = \iiint q(\lambda_1, \lambda_2, \theta) f(\lambda_1, \lambda_2) d\lambda_1 d\lambda_2 d\theta.$$

积分掉 θ 后，得到特征值的联合概率密度 *(jpdf)* 为：

$$p(\lambda_1,\lambda_2)=\tilde{C}_2\exp(-\frac{1}{2}(\lambda_1^2+\lambda_2^2))|\lambda_1-\lambda_2|$$

这里 $\tilde{C}_2=\pi C_2$.

定理 1.34.1 (GOE 特征值 jpdf). *GOE(N)* 的特征值 $\lambda_1<\lambda_2<\cdots<\lambda_N$ 的联合概率密度函数为：

$$p(\lambda_1,\ldots,\lambda_N)=\tilde{C}_N\exp\left(-\frac{N}{4}\sum_{i=1}^N\lambda_i^2\right)\prod_{1\le k<l\le N}(\lambda_l-\lambda_k)$$

乘积项 $\prod(\lambda_l-\lambda_k)$ 称为 *interacting term*，它表明特征值之间存在“排斥”*(repulsion)*，即两个特征值靠得很近的概率会变小。

证明思路. $A=(X_{kl})$ 的概率密度为 $\mathbb{P}(A)=C_N\exp(-\frac{N}{4}\mathrm{Tr}A^2)$。

进行变量变换 $A=O^TDO$，其中 $D=\mathrm{diag}(\lambda_1,\ldots,\lambda_N)$，$\lambda_1<\cdots<\lambda_N$。

利用 Lie 群 $\mathrm{SO}(N)$ 及其 Lie 代数 $\mathfrak{so}(N)$ 进行参数化，令 $O=e^{-H}$，其中 H 为反对称矩阵 ($H^T=-H$)。则 $O^T=(e^{-H})^T=e^{-H^T}=e^H$，故 $O^TO=e^He^{-H}=I_N$。从而 $A=O^TDO=e^HDe^{-H}$。

我们需要计算该变换的雅可比行列式 (Jacobian)。在 $H=0$ 点计算 Jacobian，此时 $O=I_N$。变换的微分形式为：

$$dA=(dH)D-D(dH)+dD$$

写出分量形式：

$$dx_{ij}=\lambda_j dh_{ij}-\lambda_i dh_{ij}+\delta_{ij}d\lambda_i=(\lambda_j-\lambda_i)dh_{ij}+\delta_{ij}d\lambda_i$$

由此可得 Jacobian $J=\det(\frac{\partial x}{\partial(\lambda,h)})=\prod_{k<l}(\lambda_l-\lambda_k)$。

最终联合密度为 $P(A)|J|=C_N\exp(-\frac{N}{4}\sum\lambda_i^2)\prod_{k<l}(\lambda_l-\lambda_k)$。 □

注 1.34.1. 这个证明也许有些不严谨，请参考别的随机矩阵书籍。

定理 1.34.2 (GUE 特征值 jpdf). *GUE(N)* 的特征值 $\lambda_1<\cdots<\lambda_N$ 的 *jpdf* 为：

$$p(\lambda_1,\ldots,\lambda_N)=\hat{C}_N\exp\left(-\frac{N}{2}\sum_{i=1}^N\lambda_i^2\right)\prod_{1\le k<l\le N}(\lambda_l-\lambda_k)^2$$

证明是类似的，但使用酉矩阵 $U=e^{-iH}$ *(H 为厄米矩阵)* 进行参数化。

注 1.34.2 (β-系综). 对 *GSE (辛系综, S 为辛矩阵)*，结论变为 $\prod(\lambda_l-\lambda_k)^4$。

从而可定义 β-系综：$\exp(-D\sum\lambda_i^2)\prod_{k<l}(\lambda_l-\lambda_k)^\beta$ *($\beta>0$)*

一般的酉系综为 $C_{V,N}\exp(-\frac{N}{2}\sum V(\lambda_i))\prod_{k<l}(\lambda_l-\lambda_k)^2$。

注 1.34.3 (Vandermonde 行列式). 注意到 $\prod_{k<l}(\lambda_l-\lambda_k)$ 是范德蒙行列式，由行列式的性有：

$$\prod_{1\le k<l\le N}(\lambda_l-\lambda_k)=\det\begin{pmatrix}1&1&\ldots&1\\ \lambda_1&\lambda_2&\ldots&\lambda_N\\ \vdots&\vdots&\ddots&\vdots\\ \lambda_1^{N-1}&\lambda_2^{N-1}&\ldots&\lambda_N^{N-1}\end{pmatrix}=\det(P_{i-1}(\lambda_j))_{i,j=1}^N$$

其中 $P_k(x)$ 是至多 k 次多项式。在 *GUE* 的 *jpdf* 中，可以选取特殊的 P_k：*Hermite* 多项式。

1.35　GUE 与 Hermite 核

定义 1.35.1 (Hermite 多项式). *a)* $H_n(x)$ 是首项系数为 1 的 n 次多项式。

b) $\forall n, m \geq 0$,

$$\int_{\mathbb{R}} \frac{1}{\sqrt{2\pi}} e^{-x^2/2} H_m(x) H_n(x) dx = n! \delta_{n,m}$$

注 1.35.1. H_n 可通过 *Gram-Schmidt* 正交化得到。

性质 1.35.1. *(1) Rodrigues* 公式:

$$H_n(x) = (-1)^n e^{\frac{x^2}{2}} \frac{d^n}{dx^n}(e^{-\frac{x^2}{2}})$$

$$H_0(x) = 1, \quad H_1(x) = x, \quad H_2(x) = x^2 - 1.$$

(2) Three terms recurrence relation:

$$xH_n(x) = H_{n+1}(x) + nH_{n-1}(x)$$

(3) Differential equation:

$$y''(x) - xy'(x) + ny(x) = 0$$

$$L(f) = f'' - xf', \quad L(H_n) = -nH_n(x)$$

习题 1. 证明性质 *5.3.*

证明. (1) 由 Gram-Schmidt 正交化过程，在给定内积下，首一正交多项式序列是唯一的。从而只需验证

$$H_n(x) = (-1)^n e^{\frac{x^2}{2}} \frac{d^n}{dx^n}(e^{-\frac{x^2}{2}})$$

满足条件。首先容易证明 H_n 确实是首一的 n 次多项式。

对任何次数 $m < n$ 的多项式 $P(x)$，由于 $e^{-\frac{x^2}{2}}$ 下降速度远快于任何多项式，

$$\begin{aligned}
\int_{\mathbb{R}} \frac{d^n}{dx^n}(e^{-\frac{x^2}{2}}) \cdot P(x) dx &= \frac{d^{n-1}}{dx^{n-1}}(e^{-\frac{x^2}{2}}) \cdot P(x) \Big|_{-\infty}^{\infty} - \int_{-\infty}^{\infty} \frac{d^{n-1}}{dx^{n-1}}(e^{-\frac{x^2}{2}}) \cdot P'(x) dx \\
&= -\int_{-\infty}^{\infty} \frac{d^{n-1}}{dx^{n-1}}(e^{-\frac{x^2}{2}}) P'(x) dx \\
&= \cdots = (-1)^n \int_{-\infty}^{\infty} (e^{-\frac{x^2}{2}}) \cdot P^{(n)}(x) dx = 0
\end{aligned}$$

从而

$$\forall m \neq n, \quad \int_{\mathbb{R}} \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} H_m(x) H_n(x) dx = 0.$$

对 $m = n$，

$$\begin{aligned}
\int_{\mathbb{R}} \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} \cdot \left[(-1)^n e^{\frac{x^2}{2}} \frac{d^n}{dx^n}(e^{-\frac{x^2}{2}}) \right]^2 dx &= \frac{(-1)^n}{\sqrt{2\pi}} \int_{\mathbb{R}} H_n(x) \frac{d^n}{dx^n}(e^{-\frac{x^2}{2}}) dx \\
&= (\text{分部积分 } n \text{ 次}) \frac{(-1)^n}{\sqrt{2\pi}} \int_{\mathbb{R}} \frac{d^n}{dx^n}(H_n(x))(e^{-\frac{x^2}{2}}) dx \\
&= (H_n \text{ 为 } n \text{ 次首一多项式}) \frac{n!}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{-\frac{x^2}{2}} dx \\
&= n!
\end{aligned}$$

(2) 由于 $xH_n(x)$ 是 $n+1$ 次多项式，其可表示为 Hermite 多项式的线性组合：

$$xH_n(x)=\sum_{k=0}^{n+1}C_kH_k(x),\quad C_k=\frac{\langle xH_n,H_k\rangle}{\langle H_k,H_k\rangle}=\frac{\langle xH_n,H_k\rangle}{k!}$$

若 $k<n-1$，$C_k=\frac{\langle H_n,xH_k\rangle}{k!}=0$。

$$C_{n-1}=\frac{\langle xH_n,H_{n-1}\rangle}{(n-1)!}=\frac{\langle H_n,xH_{n-1}\rangle}{(n-1)!}$$

由于 $xH_{n-1}(x)$ 首一、次数为 n，故其低次项与 H_n 的内积为 0, 故 $C_{n-1}=\frac{\langle H_n,H_n\rangle}{(n-1)!}=n.$

被积函数为奇函数，有

$$C_n=\frac{\langle xH_n,H_n\rangle}{n!}=\frac{1}{n!}\int_{\mathbb{R}}\frac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}}\cdot x(H_n(x))^2dx=0$$

而直接由 xH_n,H_{n+1} 均为首一 $n+1$ 次多项式即得 $C_{n+1}=1.$

因此：

$$xH_n(x)=H_{n+1}(x)+nH_{n-1}(x)$$

(3)

$$\begin{aligned}H_n'(x)&=(-1)^n\cdot\frac{d}{dx}\left[e^{\frac{x^2}{2}}\frac{d^n}{dx^n}(e^{-\frac{x^2}{2}})\right]\\&=(-1)^n\cdot e^{\frac{x^2}{2}}\left[x\frac{d^n}{dx^n}(e^{-\frac{x^2}{2}})+\frac{d^{n+1}}{dx^{n+1}}(e^{-\frac{x^2}{2}})\right]\\&=xH_n(x)-H_{n+1}(x)=nH_{n-1}(x).\end{aligned}$$

因此：

$$H_n'(x)-xH_n'(x)+nH_n(x)=nH_{n-1}(x)-nxH_{n-1}(x)+nH_n(x)=0$$

□

还有几个其他常用的多项式，如：

- **Laguerre 多项式**:

$$I=(0,+\infty),\quad \omega_L(x)=x^\alpha e^{-x}.$$

- **Jacobi 多项式**:

$$I=(-1,1),\quad \omega(x)=(x+1)^\alpha(1-x)^\beta$$

若 $\alpha=\beta=0$，则 Jacobi 多项式成为 Legendre 多项式；若 $\alpha=\beta=\pm\frac{1}{2}$, 则 Jacobi 多项式成为 Chebyshev 多项式。

用处：**Gauss 积分法则**

$$\int_I f(x)\omega(x)dx\approx\sum f(x_i)\omega_i$$

这里 x_i 是节点，ω_i 可以看做权重。

$f(x)=x^i,\quad i=0,1,\dots,2n-1$ 时, 上式等号严格成立. 这里 x_i 取成 $P_n(x)$ 的零点.

现在我们回到上小节节末，使用 Hermite 核来处理 GUE 的联合特征值分布函数。既有：

$$\Delta(\lambda_1,\dots,\lambda_N)=\det(H_{i-1}(\lambda_j))_{i,j=1}^N$$

从而

$$\begin{aligned}q(\lambda_1,\dots,\lambda_N)&=\hat{C}_N e^{-\frac{1}{2}\sum\limits_{i=1}^N\lambda_i^2}\Delta(\lambda_1,\dots,\lambda_N)^2\\&=(\text{做换元}\mu_i=\sqrt{N}\lambda_i)\quad \hat{C}_N e^{-\frac{1}{2N}\sum\limits_{i=1}^N\mu_i^2}\Delta(\frac{\mu_1}{\sqrt{N}},\dots,\frac{\mu_N}{\sqrt{N}})^2(\frac{1}{\sqrt{N}})^{N(N-1)}\end{aligned}$$

这里 μ_i 为未归一的 GUE 矩阵 $\sqrt{N}A_N$ 的特征值，$(\mu_1,\dots,\mu_N)\in\mathbb{R}^N$, 未排序。

进而 μ_i 的联合分布为：

$$\begin{aligned}p(\mu_1,\dots,\mu_N)&=\tilde{C}_N e^{-\frac{1}{2}(\mu_1^2+\dots+\mu_N^2)}\Delta(\mu_1,\dots,\mu_N)^2\\&=\tilde{C}_N e^{-\frac{1}{2}(\mu_1^2+\dots+\mu_N^2)}\det[H_{i-1}(\mu_j)]^2\\&=\tilde{C}_N[\det(e^{-\frac{1}{4}\mu_j^2}H_{i-1}(\mu_j))]^2\end{aligned}$$

这里 $\tilde{C}_N=\hat{C}_N(\frac{1}{\sqrt{N}})^{N(N-1)}N!$.

定义 1.35.2. *H_n 是 n 次 Hermite 多项式。定义 Hermite 函数：*

$$\Psi_n(x)=(2\pi)^{-\frac{1}{4}}(n!)^{-\frac{1}{2}}e^{-\frac{1}{4}x^2}H_n(x).$$

则其满足：

$$\int_{\mathbb{R}}\Psi_n(x)\Psi_m(x)dx=\frac{1}{\sqrt{2\pi}}\frac{1}{\sqrt{n!m!}}\int_{\mathbb{R}}H_n(x)H_m(x)e^{-\frac{1}{2}x^2}dx=\delta_{n,m}$$

那么，由于 $(\det M)^2=\det M\cdot\det M^t=\det(M\cdot M^t)$, 有

$$p(\mu_1,\dots,\mu_N)=C_N[\det(\Psi_{i-1}(\mu_j))_{i,j=1}^N]^2=C_N(\det K_N(\mu_i,\mu_j)_{i,j=1}^N).$$

这里 $K_N(x,y)=\sum\limits_{k=0}^{N-1}\Psi_k(x)\Psi_k(y)$，其中 Ψ_k 是 Hermite 函数，称 K_N 为 Hermite 核。

类似地, 对一般权函数 $\omega(x)$, 可以写成

$$\prod_{i=1}^N\omega(x_i)\Delta(x_1,\dots,x_n)^2=\det(K_N(x_i,x_j))$$

其中 K_N 用 ω 表示 (这里用的是 Hermite 多项式对应的权函数).

性质 1.35.2. *N 阶 Hermite 核是一个再生核 (reproducing kernel), i.e.*

$$\int_{\mathbb{R}}K_N(x,u)K_N(u,y)du=K_N(x,y).$$

证明.

$$\begin{aligned}\text{LHS}&=\int_{\mathbb{R}}\left(\sum_{k=0}^{N-1}\Psi_k(x)\Psi_k(u)\right)\left(\sum_{l=0}^{N-1}\Psi_l(u)\Psi_l(y)\right)du\\&=\sum_{k=0}^{N-1}\sum_{l=0}^{N-1}\Psi_k(x)\Psi_l(y)\int_{\mathbb{R}}\Psi_k(u)\Psi_l(u)du\\&=\sum_{k=0}^{N-1}\Psi_k(x)\Psi_k(y)=K_N(x,y).\end{aligned}$$

□

引理 1.35.1. *$K:\mathbb{R}^2\to\mathbb{R}$ 是再生核, 则对 $n\geq 2$,*

$$\int_{\mathbb{R}}\det(K(x_i,x_j))_{i,j=1}^{n}dx_n=(d-n+1)\det(K(x_i,x_j))_{i,j=1}^{n-1}$$

其中 $d=\int K(x,x)dx$.

证明. $n=2$ 时,

$$\begin{aligned}&\int_{\mathbb{R}}\det\begin{pmatrix}K(x_1,x_1)&K(x_1,x_2)\\K(x_2,x_1)&K(x_2,x_2)\end{pmatrix}dx_2\\&=\int_{\mathbb{R}}(K(x_1,x_1)K(x_2,x_2)-K(x_1,x_2)K(x_2,x_1))dx_2\\&=dK(x_1,x_1)-K(x_2,x_2)=(d-1)K(x_1,x_1).\end{aligned}$$

$n\geq 2$ 时留作习题. □

习题 2. *对一般的 n 证明引理 5.6.*

证明.

$$\det(K(x_i,y_j))_{i,j=1}^{n}=\sum_{\sigma\in S_n}\operatorname{sgn}(\sigma)\cdot\prod_{i=1}^{n}K(x_i,x_{\sigma(i)})$$

将 S_n 分割为两个不交集合：

$$A=\{\sigma\in S_n:\sigma(n)=n\},\quad B=\{\sigma\in S_n:\sigma(n)\neq n\}$$

对 $\sigma\in A$，

$$\begin{aligned}&\prod_{i=1}^{n}K(x_i,x_{\sigma(i)})=K(x_n,x_n)\prod_{i=1}^{n-1}K(x_i,x_{\sigma(i)})\\&\Rightarrow\int_{\mathbb{R}}\prod_{i=1}^{n}K(x_i,x_{\sigma(i)})dx_n=d\prod_{i=1}^{n-1}K(x_i,x_{\sigma(i)})\end{aligned}$$

对 $\sigma\in B$，

$$\prod_{i=1}^{n}K(x_i,x_{\sigma(i)})=K(x_j,x_n)K(x_n,x_k)\prod_{i\neq j}K(x_i,x_{\sigma(i)})$$

其中 $j=\sigma^{-1}(n),k=\sigma(n)$

$$\begin{aligned}\Rightarrow\int_{\mathbb{R}}\prod_{i=1}^{n}K(x_i,x_{\sigma(i)})dx_n&=\left(\prod_{i\neq j,n}K(x_i,x_{\sigma(i)})\right)\int_{\mathbb{R}}K(x_j,x_n)K(x_n,x_k)dx\\&=\left(\prod_{i\neq j,n}K(x_i,x_{\sigma(i)})\right)K(x_j,x_k)\end{aligned}$$

定义 $\sigma'\in S_{n-1}$：对于 $i\neq j$，$\sigma'(i)=\sigma(i)$，且 $\sigma'(j)=k$。则 $\operatorname{sgn}(\sigma')=-\operatorname{sgn}(\sigma)$（交换 (n,k) 这一逆序对）。

且对每个 $\sigma'\in S_{n-1}$，在 B 中有 $(n-1)$ 个 σ 与之对应（因为 j 可取 1 到 $n-1$）。

因此：

$$\begin{aligned}\int_{\mathbb{R}} \det(K(x_i,x_j))_{i,j=1}^n dx_n &= \sum_{\sigma\in A}\int_{\mathbb{R}}\prod_{i=1}^n K(x_i,x_{\sigma(i)})dx_n + \sum_{\sigma\in B}\int_{\mathbb{R}}\prod_{i=1}^n K(x_i,x_{\sigma(i)})dx_n\\ &= d\sum_{\sigma\in S_{n-1}}\operatorname{sgn}(\sigma)\cdot\prod_{i=1}^{n-1}K(x_i,x_{\sigma(i)})\\ &+ (n-1)\cdot\sum_{\sigma'\in S_{n-1}}(-\operatorname{sgn}(\sigma'))\prod_{i=1}^{n-1}K(x_i,x_{\sigma'(i)})\\ &= (d-n+1)\det(K(x_i,x_j))_{i,j=1}^{n-1}\end{aligned}$$

□

推论 1.35.1. 记 K_N 为 *Hermite* 核, 由于

$$d=\int K_N(x,x)dx=\sum_{i=0}^{N-1}\int\Psi_i(x)\Psi_i(x)dx=n$$

$$\begin{aligned}&\int_{\mathbb{R}}\dots\int_{\mathbb{R}}(\det(K_N(x_i,x_j)))_{i,j=1}^n dx_1\dots dx_n\\ &=(d-n+1)\int_{\mathbb{R}}\dots\int_{\mathbb{R}}(\det(K_N(x_i,x_j)))_{i,j=1}^{n-1}dx_1\dots dx_{n-1}\\ &=\dots=(d-n+1)\dots(d-1)d=n!\end{aligned}$$

又因为

$$\begin{aligned}1&=\int_{\mathbb{R}^N}p_N(\mu_1,\dots,\mu_N)d\mu_1\dots d\mu_N\\ &=C_N\int_{\mathbb{R}^N}\det(K_N(\mu_i,\mu_j))_{i,j=1}^n\prod_{i=1}^n d\mu_i\end{aligned}$$

因此 $C_N=\frac{1}{n!}$

定理 1.35.1. 未归一的 $GUE(N)$ 的平均特征值密度是

$$\begin{aligned}P_N(\mu)&=\frac{1}{N}K_N(\mu,\mu)=\frac{1}{N}\sum_{k=0}^{N-1}\Psi_k(\mu)^2\\ &=\frac{1}{\sqrt{2\pi}}\frac{1}{N}\sum_{k=0}^{N-1}\frac{1}{k!}H_k(\mu)^2e^{-\frac{1}{2}\mu^2}.\end{aligned}$$

证明. $P(\mu_1,\dots,\mu_N)$ 是 jpdf, 即 N 个特征值位于 $\mu_1,\dots,\mu_N$ 的概率.

$$P_N(y)=\int_{\mathbb{R}^{N-1}}P(y_1,\dots,y_{N-1},y)dy_1\dots dy_{N-1}$$

$$\begin{aligned}P_N(\mu)&=\int_{\mathbb{R}^{N-1}}P(\mu_1,\dots,\mu_{N-1},\mu)d\mu_1\dots d\mu_{N-1}\\ &=\frac{1}{N!}\int_{\mathbb{R}^{N-1}}\det(K_N(\mu_i,\mu_j))_{i,j=1}^N d\mu_1\dots d\mu_{N-1}\\ &=\frac{(N-1)!}{N!}K_N(\mu,\mu)=\frac{1}{N}K_N(\mu,\mu)\end{aligned}$$

□